TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN

LƯƠNG CHÍ TRUNG

XÂY DỰNG TẬP DỮ LIỆU CHO BÀI TOÁN TRÍCH XUẤT SỰ KIỆN PHÁP LÝ TRÊN MIỀN DỮ LIỆU TIẾNG VIỆT

KHÓA LUẬN TỐT NGHIỆP

KHOA HỌC MÁY TÍNH

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN

LƯƠNG CHÍ TRUNG - 52200166

XÂY DỰNG TẬP DỮ LIỆU CHO BÀI TOÁN TRÍCH XUẤT SỰ KIỆN PHÁP LÝ TRÊN MIỀN DỮ LIỆU TIẾNG VIỆT

KHÓA LUẬN TỐT NGHIỆP

KHOA HỌC MÁY TÍNH

Người hướng dẫn
ThS. Dung Cẩm Quang

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Em xin bày tỏ lòng biết ơn sâu sắc đến ThS. Dung Cẩm Quang vì sự hướng dẫn tận tình và những định hướng chuyên môn quý báu trong suốt quá trình thực hiện khóa luận tốt nghiệp. Đồng thời, em xin trân trọng cảm ơn Trường Đại học Tôn Đức Thắng và quý thầy cô trong khoa đã tạo điều kiện thuận lợi và hỗ trợ em trong quá trình học tập và nghiên cứu.

Em cũng xin gửi lời cảm ơn đến gia đình và bạn bè đã luôn động viên và là chỗ dựa tinh thần vững chắc cho em. Những sự hỗ trợ đó đã góp phần quan trọng giúp em hoàn thành khóa luận này.

TP. Hồ Chí Minh, ngày ... tháng ... năm 2026

Tác giả

(Ký tên và ghi rõ họ tên)

Công trình được hoàn thành tại Trường Đại học Tôn Đức Thắng

Cán bộ hướng dẫn khoa học: .....

.....…

(Ghi rõ học hàm, học vị, họ tên và chữ ký)

Khóa luận tốt nghiệp được bảo vệ tại **Hội đồng đánh giá Khóa luận tốt nghiệp của Trường Đại học Tôn Đức Thắng** vào ngày… /…/……

Xác nhận của Chủ tịch Hội đồng đánh giá Khóa luận tốt nghiệp và Trưởng khoa quản lý chuyên ngành sau khi nhận Khóa luận tốt nghiệp đã được sửa chữa (nếu có).

CHỦ TỊCH HỘI ĐỒNG	**TRƯỞNG KHOA**
……..	……

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH
TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Tôi xin cam đoan đây là công trình nghiên cứu của riêng tôi và được sự hướng dẫn khoa học của ThS. Dung Cẩm Quang. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong Khóa luận tốt nghiệp còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào tôi xin hoàn toàn chịu trách nhiệm về nội dung Khóa luận tốt nghiệp của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày ... tháng ... năm 2026

Tác giả

(Ký tên và ghi rõ họ tên)

XÂY DỰNG TẬP DỮ LIỆU CHO BÀI TOÁN TRÍCH XUẤT SỰ KIỆN PHÁP LÝ TRÊN MIỀN DỮ LIỆU TIẾNG VIỆT

TÓM TẮT

Việc trích xuất sự kiện từ các văn bản pháp lý đóng vai trò quan trọng trong việc tự động hóa quá trình phân tích và xử lý lượng lớn dữ liệu pháp lý. Trích xuất sự kiện ở cấp độ văn bản đặc biệt quan trọng vì các sự kiện pháp lý thường không chỉ nằm trong một câu mà trải dài qua nhiều câu, tạo ra thách thức lớn trong việc phát hiện và phân loại chúng trong một bối cảnh duy nhất. Điều này càng trở nên phức tạp trong các văn bản pháp lý tiếng Việt, nơi các sự kiện như hành vi phạm tội hoặc quyết định của tòa án thường được mô tả trong các câu chuyện dài. Tập dữ liệu VLEX (Vietnamese Legal Document-level Event Extraction) được xây dựng nhằm giải quyết thách thức này bằng cách cung cấp một chuẩn đánh giá cho các mô hình trích xuất sự kiện trong văn bản pháp lý tiếng Việt. VLEX bao gồm 7,614 văn bản đã được gán nhãn, với 11,042 sự kiện thuộc 29 loại sự kiện và 48 vai trò đối số. Dữ liệu này bao phủ sáu nhóm sự kiện chính, phản ánh sự đa dạng của các hành vi pháp lý, từ các tội phạm đến các vi phạm về tài sản, và chứa tổng cộng 51,697 đối số trên tất cả các văn bản, đạt mức độ đồng thuận IAA 81.3%. Đây là tập dữ liệu đầu tiên về trích xuất sự kiện cấp độ văn bản trong các văn bản pháp lý tiếng Việt, đồng thời cung cấp cái nhìn sâu sắc về việc xử lý các văn bản đa sự kiện. Khoảng 19.5% văn bản trong VLEX chứa hơn một sự kiện, điều này thể hiện tính thử thách đối với các mô hình trích xuất sự kiện khi phải xử lý các tình huống đa sự kiện và xác định các sự kiện không bị chồng lấn nhau. Các mô hình cơ sở cũng được chạy thực nghiệm trên tập dữ liệu để làm kết quả tham chiếu. Các lỗi phổ biến như sai vùng văn bản và lỗi đối số đồng tham chiếu cũng được chỉ ra như một thách thức mới trên tập dữ liệu. Trong tương lai, các cải tiến có thể bao gồm việc tích hợp mô hình ngôn ngữ lớn vào quy trình gán nhãn để nâng cao hiệu quả và tính nhất quán, cũng như mở rộng tập dữ liệu để bao phủ các lĩnh vực pháp lý khác như luật dân sự và luật hôn nhân gia đình.

CONSTRUCTING A DATASET FOR THE TASK OF LEGAL EVENT EXTRACTION IN THE VIETNAMESE LANGUAGE

ABSTRACT

Event extraction from legal documents plays a crucial role in automating the analysis and processing of large amounts of legal data. Extracting events at the document level is particularly important because legal events often do not occur within a single sentence but span across multiple sentences, creating a significant challenge in detecting and classifying them within a single context. This becomes even more complex in Vietnamese legal texts, where events such as criminal acts or court decisions are often described in lengthy narratives. The VLEX (Vietnamese Legal Document-level Event Extraction) dataset was developed to address this challenge by providing a benchmark for evaluating event extraction models in Vietnamese legal texts. VLEX consists of 7,614 annotated documents, with 11,042 events categorized into 29 event types and 48 argument roles. The dataset covers six main event groups, reflecting the diversity of legal actions, from crimes to property violations, and contains a total of 51,697 arguments across all documents, achieving an Inter-Annotator Agreement (IAA) of 81.3%. This is the first document-level event extraction dataset for Vietnamese legal texts, providing valuable insights into handling multi-event documents. Approximately 19.5% of the documents in VLEX contain more than one event, which presents a challenge for event extraction models in handling multi-event scenarios and ensuring that events do not overlap. VLEX has addressed several key challenges in event extraction, including multi-event scenarios, argument role identification, and ensuring the legal relevance of event representations. In the future, improvements could include integrating large language models into the annotation process to enhance efficiency and consistency, as well as expanding the dataset to cover other legal domains such as civil law and family law.

MỤC LỤC

DANH MỤC HÌNH VẼ viii

DANH MỤC BẢNG BIỂU ix

DANH MỤC CÁC CHỮ VIẾT TẮT x

CHƯƠNG 1. MỞ ĐẦU VÀ TỔNG QUAN ĐỀ TÀI 1

1.1 Lý do chọn đề tài 1

1.2 Mục tiêu thực hiện đề tài 2

1.3 Đối tượng nghiên cứu 2

1.4 Phạm vi nghiên cứu 2

1.5 Phương pháp nghiên cứu 3

1.6 Ý nghĩa khoa học và thực tiễn 4

CHƯƠNG 2. CÔNG TRÌNH NGHIÊN CỨU CÓ LIÊN QUAN 6

2.1 Trích xuất sự kiện ở cấp độ văn bản 6

2.2 Một số tập dữ liệu trong bài toán trích xuất sự kiện pháp lý 10

2.3 Một số tập dữ liệu trích xuất sự kiện trên miền ngôn ngữ tiếng Việt 15

CHƯƠNG 3. CƠ SỞ LÝ THUYẾT 19

3.1 Mô hình hóa bài toán 19

3.2 Sự kiện 19

3.3 Lược đồ sự kiện 22

3.4 Phương pháp đánh giá Cohen's kappa 23

3.5 Một số mô hình nổi bật trong bài toán trích xuất sự kiện ở cấp độ văn bản 24

3.5.1 Document-level Chinese Financial Event Extraction (DCFEE) 24

3.5.2 Document to Event Directed Acyclic Graph (Doc2EDAG) 26

3.5.3 Graph-based Interaction Model with a Tracker (GIT) *27*

3.5.4 Pseudo-Trigger-aware Pruned Complete Graph (PTPCG) *28*

CHƯƠNG 4. QUY TRÌNH XÂY DỰNG TẬP DỮ LIỆU 30

4.1 Chọn lọc dữ liệu 30

4.2 Xây dựng lược đồ dữ liệu sự kiện 30

4.3 Trích lọc dữ liệu 36

4.3.1 Trích lọc văn bản *36*

4.3.2 Trích lọc từ kích hoạt sự kiện *36*

4.3.3 Trích xuất sự kiện *37*

CHƯƠNG 5. PHÂN TÍCH THỐNG KÊ DỮ LIỆU 41

5.1 Kích thước dữ liệu 41

5.2 Phân phối dữ liệu 44

CHƯƠNG 6. THỰC NGHIỆM 46

6.1 Mô hình cơ sở và phương pháp đánh giá 46

6.2 Cài đặt thực nghiệm 46

6.3 Kết quả thực nghiệm 47

6.4 Phân tích lỗi 49

CHƯƠNG 7. KẾT LUẬN 52

7.1 Kết luận 52

7.2 Hướng phát triển 52

TÀI LIỆU THAM KHẢO 54

DANH MỤC HÌNH VẼ

Hình 3.1 Kiến trúc mô hình DCFEE 25

Hình 3.2 Kiến trúc mô hình Doc2EDAG..... 26

Hình 3.3 Kiến trúc mô hình GIT 27

Hình 3.4 Kiến trúc mô hình PTPCG..... 28

Hình 4.1 Giao diện trang gán nhãn trong hệ thống đánh nhãn INCEpTION 38

Hình 5.1 Biểu đồ tròn khuyết thể hiện số lượng văn bản của top 10 loại sự kiện có số lượng văn bản nhiều nhất..... 45

DANH MỤC BẢNG BIỂU

Bảng 3.1 Ví dụ về việc trích xuất sự kiện từ mẫu văn bản đa sự kiện trong VLEX 21

Bảng 4.1 Lược đồ sự kiện của tập dữ liệu VLEX 32

Bảng 5.1 Bảng so sánh thông tin của VLEX và một số tập dữ liệu khác trong lĩnh vực pháp lý 42

Bảng 5.2 Bảng so sánh thông tin của VLEX và các tập dữ liệu trong một số lĩnh vực nổi bật..... 43

Bảng 5.3 Tỉ lệ văn bản có gãn nhãn bởi sáu nhóm sự kiện của VLEX..... 44

Bảng 6.1 Thống kê về số liệu các tập dữ liệu được chia thành để thực nghiệm..... 47

Bảng 6.2 Kết quả thực nghiệm của các mô hình cơ sở trên tập dữ liệu VLEX 47

DANH MỤC CÁC CHỮ VIẾT TẮT

CLEE	Criminal Legal Event Extraction
DCFEE	Document-level Chinese Financial Event Extraction
DEE	Document-level Event Extraction
DivorceEE	Divorce Event Extraction dataset
DLEE	Document-level Legal Event Extraction
Doc2EDAG	Document to Event Directed Acyclic Graph
DocEE	Chinese Document-level Event Extraction
DyHiLED	Dynamic Hierachical Legal Event Detection
GIT	Graph-based Interaction Model with a Tracker
LEVEN	LEgal eVENt extraction
IAA	Inter-Annotator Agreement
PTPCG	Pseudo-Trigger-aware Pruned Complete Graph
SEE	Sentence-level Event Extraction
VHE	Vietnamese Historical Events
VLEX	Vietnamese Legal Document-level Event eXtraction

CHƯƠNG 1. MỞ ĐẦU VÀ TỔNG QUAN ĐỀ TÀI

1.1 Lý do chọn đề tài

Tổng hợp và trích xuất sự kiện từ các văn bản pháp lý như bản án, hợp đồng, đơn khởi kiện, các văn bản quy phạm pháp luật hay tin tức pháp luật là một công việc vô cùng quan trọng trong quá trình tố tụng và đưa ra các quyết định chế tài. Tuy nhiên, việc xử lý nội dung này lại thường được tiến hành thủ công trên khối dữ liệu lớn khiến quy trình thực hiện mất nhiều thời gian, dễ bỏ sót sự kiện cũng như khó mở rộng quy mô lên hàng nghìn hay hàng triệu tài liệu. Trong bối cảnh đó, nhu cầu về một cấu trúc tổng quát cho các sự kiện pháp lý là cấp thiết, giúp triển khai các hệ thống nhận dạng và trích xuất sự kiện tự động. Đây cũng là tiền đề cho các tác vụ lớn như xây dựng cơ sở tri thức pháp lý (Guan et al., 2022), hệ thống tra cứu bản án theo tình huống (Joshi, Sharma, Tanikella, & Modi, 2023), dự đoán phán quyết pháp lý (Feng, Li, & Ng, 2022) và giải quyết tham chiếu đồng sự kiện (Wei et al., 2025).

Bên cạnh đó, tác vụ trích xuất sự kiện cũng đối mặt với những thách thức lớn, đặc biệt trong lĩnh vực pháp lý. Các tập dữ liệu pháp lý được công bố hiện tại chủ yếu được xây dựng trên miền ngôn ngữ tiếng Trung và tiếng Anh (Premasiri, Ranasinghe, Mitkov, El-Haj, & Frommholz, 2025), mất đi sự cân bằng về miền ngôn ngữ của dữ liệu. Luật pháp của mỗi quốc gia lại sử dụng ngôn ngữ khác nhau, do đó vô hình chung khiến việc huấn luyện mô hình trên tập dữ liệu thuộc một miền ngôn ngữ phục vụ cho mục đích trích xuất sự kiện pháp lý trên một miền ngôn ngữ khác không thực sự mang lại hiệu quả.

Chính vì vậy, chúng tôi chọn đề tài này nhằm cung cấp một tập dữ liệu về trích xuất sự kiện pháp lý cấp văn bản trên miền ngôn ngữ tiếng Việt với tên gọi **VLEX** (**V**ietnamese **L**egal Document-level **E**vent e**X**traction dataset) đóng vai trò như một thang đo đánh giá cho các mô hình trích xuất sự kiện pháp lý tại Việt Nam. Theo tìm hiểu đến thời điểm viết báo cáo này, đây là tập dữ liệu thứ ba về tác vụ trích xuất sự kiện và cũng là tập dữ liệu đầu tiên về trích xuất dữ liệu ở cấp độ văn bản trên miền dữ liệu tiếng Việt. Đồng thời, chúng tôi cũng mong muốn tập dữ liệu này góp phần

thúc đẩy các tác vụ nghiên cứu về pháp lý vốn được ảnh hưởng bởi tác vụ trích xuất sự kiện ở Việt Nam.

1.2 Mục tiêu thực hiện đề tài

Tập dữ liệu VLEX được công bố với mục tiêu trở thành thang đo tiêu chuẩn đầu tiên cho các tác vụ trích xuất sự kiện về pháp lý trên miền ngôn ngữ tiếng Việt, thể hiện tính đa dạng về hành vi phạm tội và thực thể tham gia của dữ liệu pháp lý tiếng Việt. Ngoài ra, sự kiện trong các văn bản pháp luật thường không nằm gói gọn trong một câu mà trải dài rải rác khắp các câu trong một đoạn văn bản nên vì vậy, VLEX được xây dựng với mục tiêu phản ánh đúng cách mô tả sự kiện trong các văn bản thực tế, làm tăng tính ứng dụng trong đời sống hằng ngày. Không chỉ vậy, chúng tôi cũng muốn giới thiệu về các văn bản đa sự kiện được thu thập, vừa là thách thức, vừa là cơ hội cung cấp một chuẩn đánh giá và thúc đẩy cho các hướng nghiên cứu mới về trích xuất đa sự kiện.

1.3 Đối tượng nghiên cứu

Dữ liệu thu thập cho tập dữ liệu VLEX là các văn bản pháp lý, cụ thể là các bản án xét xử đã được công bố rộng rãi, minh bạch. Để đảm bảo tính nhất quán giữa những người gán nhãn, chỉ số IAA (Inter-Annotator Agreement) được sử dụng để kiểm tra mức độ đồng thuận giữa những người gán nhãn về các tác nhân và từ kích hoạt sự kiện được đánh nhãn. Các mô hình cơ sở cũng được chạy thực nghiệm để đánh giá hiệu năng trên VLEX với hai tác vụ điền vào ô trống bảng đối số. Như các nghiên cứu trước đó (Xian et al., 2024; Yao et al., 2022), ba chỉ số đánh giá chính được chọn lần lượt là Precision, Recall và F1 Score với giá trị càng cao chứng tỏ mô hình hoạt động càng tốt trên tập dữ liệu.

1.4 Phạm vi nghiên cứu

Dữ liệu được thu thập gồm các bản án, quyết định của Tòa án nhân dân các cấp tại Việt Nam, được công bố công khai trên Trang thông tin điện tử Thư Viện

Pháp Luật[1]. Đề tài không thu thập dữ liệu từ các nguồn pháp lý khác như văn bản quy phạm pháp luật, hợp đồng, tin tức báo chí hay tài liệu nội bộ của cơ quan, tổ chức. Dữ liệu nằm trong phạm vi miền ngôn ngữ tiếng Việt, thu thập từ ngày 01/07/2017 đến hết ngày 30/11/2025 trên lĩnh vực pháp lý Hình sự nhằm bảo đảm tính đa dạng về loại sự kiện nhưng vẫn phù hợp với nguồn lực gán nhãn. Các lĩnh vực đặc thù khác (Nhân sự, Hôn nhân & gia đình, Hành chính, Lao động…) có thể được xem xét mở rộng trong các nghiên cứu tiếp theo và không nằm trong phạm vi xử lý chính của đề tài.

Đối với phạm vi kỹ thuật, nghiên cứu tập trung vào thiết kế lược đồ sự kiện, xây dựng tập dữ liệu gán nhãn và đánh giá một số mô hình cơ sở cho bài toán trích xuất sự kiện pháp lý tiếng Việt. Các vấn đề như tối ưu hóa mô hình ở quy mô rất lớn, triển khai hệ thống thời gian thực hay tích hợp sâu với hệ thống tác nghiệp của Tòa án không thuộc phạm vi nghiên cứu.

1.5 Phương pháp nghiên cứu

Đề tài sử dụng cách tiếp cận kết hợp giữa nghiên cứu định tính và định lượng. Trước hết, các bản án, quyết định được công bố công khai trên Cổng thông tin điện tử công bố bản án, quyết định của Tòa án nhân dân được thu thập và tiền xử lý để loại bỏ nhiễu, chuẩn hóa định dạng văn bản, tách cấu trúc cơ bản (phần tóm tắt, nội dung, quyết định…), đồng thời thực hiện ẩn danh ở mức cần thiết nhằm bảo đảm tuân thủ quy định về bảo mật và đạo đức nghiên cứu. Trên cơ sở khảo cứu các công trình về trích xuất sự kiện pháp lý kết hợp với đặc thù hệ thống pháp luật Việt Nam, đề tài tiến hành thiết kế một tập hợp các lược đồ sự kiện pháp lý gồm tập các kiểu sự kiện, từ kích hoạt và các tác nhân tham gia phù hợp với ngữ cảnh bản án Việt Nam, sau đó thử nghiệm và hiệu chỉnh lược đồ qua giai đoạn gán nhãn thử trên một tập dữ liệu nhỏ.

---

[1] https://thuvienphapluat.vn/

Tiếp theo, chúng tôi biên soạn bộ hướng dẫn gán nhãn chi tiết, lựa chọn công cụ gán nhãn phù hợp và tổ chức quy trình gán nhãn thủ công ở mức độ văn bản trên một số lượng mẫu nhỏ bởi các người gán nhãn có hiểu biết về pháp luật và/hoặc xử lý ngôn ngữ tự nhiên. Một phần dữ liệu được gán nhãn độc lập bởi từ hai người để tính toán chỉ số độ tin cậy (IAA) giữa người gán nhãn, qua đó đánh giá tính nhất quán của schema và quy trình gán nhãn. Sau khi hoàn thiện tập dữ liệu, đề tài tiến hành phân tích thống kê mô tả (số lượng văn bản, số lượng và phân bố các loại sự kiện cũng như đa sự kiện, vai trò, độ mất cân bằng nhãn…) nhằm làm rõ đặc điểm và mức độ đa dạng của tập dữ liệu.

Cuối cùng, để kiểm chứng tính khả dụng của tập dữ liệu và cung cấp mốc tham chiếu ban đầu cho các nghiên cứu tiếp theo, chúng tôi chạy thực nghiệm và đánh giá một số mô hình cơ sở cho bài toán trích xuất sự kiện pháp lý tiếng Việt. Các mô hình này được huấn luyện và thử nghiệm trên tập dữ liệu đã gán nhãn với các thiết lập chuẩn và được đánh giá bằng các chỉ số như Precision, Recall, F1 Score trên hai tác vụ con là phân loại sự kiện và trích xuất tác nhân tham gia sự kiện. Kết quả mô hình, cùng với phân tích lỗi, được sử dụng để thảo luận về độ khó của bài toán, những hạn chế hiện tại và đề xuất các hướng phát triển tiếp theo như mở rộng lược đồ, tăng quy mô dữ liệu hoặc tích hợp thêm các tác vụ nâng cao (đồng tham chiếu sự kiện, quan hệ thời gian – nhân quả, xây dựng đồ thị tri thức pháp lý).

1.6 Ý nghĩa khoa học và thực tiễn

Về mặt khoa học, đề tài góp phần bổ sung một nguồn ngữ liệu có gán nhãn chuyên sâu về sự kiện pháp lý tiếng Việt ở mức độ văn bản. Việc đề xuất và hiện thực hoá một tập hợp lược đồ sự kiện pháp lý phù hợp với bối cảnh hệ thống pháp luật Việt Nam giúp làm rõ hơn cách biểu hiện và cấu trúc hóa các sự kiện pháp lý trong bản án, từ đó đóng góp cho hướng nghiên cứu trích xuất sự kiện trên miền riêng biệt nói riêng và xử lý ngôn ngữ tự nhiên trong lĩnh vực pháp lý nói chung. Tập dữ liệu gán nhãn đi kèm, cùng với các mô hình cơ sở được đánh giá có hệ thống, tạo ra một thang đo chuẩn hóa cho cộng đồng nghiên cứu trong và ngoài nước, giúp các công trình sau này có điểm so sánh khách quan khi đề xuất mô hình, kiến trúc hoặc phương

pháp học mới. Ngoài ra, quá trình xây dựng bộ hướng dẫn gán nhãn, đánh giá độ tin cậy giữa người gán nhãn và phân tích lỗi cũng cung cấp thêm bằng chứng thực nghiệm về đặc thù ngôn ngữ pháp lý tiếng Việt, góp phần làm phong phú thêm cơ sở dữ liệu cho các nghiên cứu liên quan đến ngôn ngữ học pháp lý.

Về mặt thực tiễn, tập dữ liệu trích xuất sự kiện pháp lý tiếng Việt là bước nền quan trọng để phát triển các ứng dụng hỗ trợ hoạt động tư pháp và pháp lý. Các sự kiện được cấu trúc hoá từ bản án có thể được khai thác để xây dựng cơ sở tri thức pháp lý, hệ thống tra cứu bản án theo tình huống, hoặc hệ thống hỏi đáp pháp luật thân thiện hơn với người dùng, khi thông tin không chỉ dừng ở mức từ khóa mà được biểu diễn dưới dạng quan hệ nhân quả. Về lâu dài, những ứng dụng như vậy có thể hỗ trợ luật sư, thẩm phán, cán bộ pháp lý và doanh nghiệp trong việc tra cứu án lệ, phân tích rủi ro, nhận diện mẫu tranh chấp lặp lại, từ đó góp phần nâng cao hiệu quả và tính minh bạch của hoạt động xét xử. Ngoài ra, tập dữ liệu và quy trình xây dựng của đề tài có thể được tái sử dụng và mở rộng cho các loại văn bản pháp lý khác (hợp đồng, văn bản quy phạm pháp luật, tài liệu tư vấn…), cũng như làm nền tảng cho các tác vụ nâng cao như đồng tham chiếu sự kiện, phân tích quan hệ thời gian – nhân quả giữa các sự kiện hay dự đoán phán quyết, qua đó tăng giá trị ứng dụng của công nghệ xử lý ngôn ngữ tự nhiên trong lĩnh vực pháp luật tại Việt Nam.

CHƯƠNG 2. CÔNG TRÌNH NGHIÊN CỨU CÓ LIÊN QUAN

2.1 Trích xuất sự kiện ở cấp độ văn bản

Trong giai đoạn đầu của nghiên cứu trích xuất sự kiện, phần lớn các công trình được xây dựng trên giả định rằng thông tin sự kiện có thể được nhận diện và hoàn thiện trong phạm vi một câu. Trên cơ sở đó, các bộ dữ liệu kinh điển như ACE 2005 *(Guideline: ACE Event Descriptions (V5)* hay TAC KBP (Ji & Grishman, 2011) đã định hình khuôn khổ chuẩn cho bài toán, trong đó hệ thống cần xác định từ kích hoạt, phân loại loại sự kiện và gán các thành phần tham gia vào những vai nghĩa tương ứng ngay trong câu chứa sự kiện. Cách tiếp cận này tạo điều kiện thuận lợi cho việc thiết kế mô hình, bởi phạm vi ngữ cảnh được giới hạn, quan hệ cú pháp tương đối rõ ràng và việc suy luận không cần mở rộng ra ngoài câu hiện tại. Vì vậy, trong một thời gian dài, trích xuất sự kiện ở cấp độ câu giữ vai trò trung tâm trong lĩnh vực trích xuất sự kiện.

Tuy nhiên, cách tiếp cận này sớm bộc lộ những giới hạn khi áp dụng vào văn bản thực tế. (Xiang & Wang, 2019) đã phân biệt tương đối rõ giữa trích xuất sự kiện ở cấp độ câu và trích xuất sự kiện ở cấp độ văn bản, đồng thời chỉ ra rằng phần lớn các bộ dữ liệu và mô hình trước đó gần như chỉ tập trung vào cấp độ câu. Sự phân biệt này có ý nghĩa không chỉ về mặt phạm vi dữ liệu đầu vào mà còn về bản chất của đối tượng cần trích xuất. Ở cấp độ câu, mô hình chủ yếu xử lý những tín hiệu ngôn ngữ cục bộ. Ngược lại, ở cấp độ văn bản, thông tin sự kiện thường được phân tán qua nhiều câu, nhiều đoạn, thậm chí được biểu đạt gián tiếp thông qua hiện tượng đồng tham chiếu, tỉnh lược hoặc các quan hệ diễn ngôn. Điều đó cho thấy giả định rằng mỗi câu chứa một sự kiện hoàn chỉnh chỉ phù hợp với những trường hợp đơn giản, trong khi phần lớn văn bản tự nhiên lại không tuân theo cấu trúc đó.

Trong thực tế, các thành phần của một sự kiện thường không cùng xuất hiện trong một câu. Câu chứa từ kích hoạt có thể chỉ nêu hành động hoặc trạng thái trung tâm, còn các vai nghĩa như chủ thể, đối tượng, thời gian, địa điểm hoặc kết quả lại nằm ở những câu trước hoặc sau đó. Trong nhiều trường hợp, một thực thể được giới

thiệu ở đầu văn bản nhưng những lần đề cập tiếp theo chỉ xuất hiện dưới dạng đại từ, mô tả rút gọn hoặc biểu thức thay thế. Nếu mô hình chỉ xử lý từng câu một cách độc lập thì khả năng phục hồi cấu trúc sự kiện đầy đủ sẽ bị hạn chế đáng kể. Đây là lý do khiến hướng nghiên cứu trích xuất sự kiện ở cấp độ văn bản dần trở thành xu thế tất yếu.

Một trong những công trình tiêu biểu mở đầu cho hướng này là DCFEE, nghiên cứu này nhấn mạnh rằng trong miền tài chính, phần lớn các phương pháp hiện có vào thời điểm đó chỉ xử lý sự kiện trong phạm vi một câu, trong khi sự kiện tài chính trong thực tế thường được trình bày trên toàn văn bản (Yang, Chen, Liu, Xiao, & Zhao, 2018). Điều này đặc biệt rõ trong các bản tin tài chính, nơi thông tin về một thương vụ, một vụ kiện, một đợt đầu tư hay một thay đổi nhân sự cấp cao thường được mô tả theo nhiều bước, rải rác ở nhiều câu với mức độ tường minh khác nhau. Đóng góp quan trọng của DCFEE là chuyển trọng tâm từ nhận diện tín hiệu cục bộ sang xây dựng hệ thống có khả năng tổng hợp các mảnh thông tin phân bố trong toàn bộ tài liệu. Có thể xem đây là một bước chuyển có tính định hướng, bởi nó cho thấy rõ rằng khó khăn của bài toán không còn nằm riêng ở nhận diện trigger mà ở khả năng tái cấu trúc toàn bộ khung sự kiện từ các bằng chứng rời rạc.

Sau DCFEE, Doc2EDAG tiếp tục làm rõ hơn những hạn chế căn bản của mô hình cấp câu. Công trình này chỉ ra hai vấn đề nổi bật, thứ nhất, các đối tượng tham gia của cùng một sự kiện có thể xuất hiện ở nhiều câu khác nhau nên không thể được thu hồi đầy đủ bằng một mô hình chỉ khai thác ngữ cảnh trong câu và thứ hai, một văn bản có thể đồng thời chứa nhiều sự kiện, thậm chí nhiều sự kiện cùng loại, với các thực thể tham gia đan xen và chồng lấn (Zheng, Cao, Xu, & Bian, 2019). Từ đó, Doc2EDAG đề xuất biểu diễn tài liệu dưới dạng một đồ thị dựa trên thực thể nhằm mô hình hóa cấu trúc sự kiện ở quy mô toàn văn bản. Điểm đáng chú ý ở đây là đơn vị xử lý không còn là câu riêng lẻ mà là toàn bộ tài liệu với mạng lưới quan hệ giữa các thực thể. Cách tiếp cận này phản ánh một thay đổi quan trọng về phương pháp luận: thay vì trích xuất cục bộ rồi hợp nhất, mô hình được thiết kế để suy luận trực tiếp trên cấu trúc toàn cục của văn bản.

Một hướng phát triển khác có ý nghĩa lớn là bộ dữ liệu RAMS với từ kích hoạt sự kiện đã được cho trước, nhiệm vụ trọng tâm lại là xác định các tác nhân tham gia trong phạm vi nhiều câu xung quanh từ kích hoạt (Ebner, Xia, Culkin, Rawlins, & Van Durme, 2020). Cụ thể, đối tượng tham gia có thể nằm ở bất kỳ câu nào trong năm câu trước và năm câu sau câu chứa từ kích hoạt. Thiết kế như vậy giúp nhấn mạnh rằng ngay cả khi bài toán phát hiện sự kiện đã được đơn giản hóa bằng cách cố định từ kích hoạt, việc liên kết vai nghĩa xuyên câu vẫn là một thách thức lớn. RAMS vì thế có vai trò quan trọng trong việc tách riêng và làm nổi bật năng lực suy luận liên câu, bao gồm khả năng theo dõi thực thể, xử lý đồng tham chiếu và tổng hợp thông tin ngữ nghĩa phân tán trong văn bản.

Những khó khăn này được (S. Li, Ji, & Han, 2021) khái quát ở mức tổng quan hơn khi nhấn mạnh ba vấn đề cốt lõi của trích xuất sự kiện ở cấp độ văn bản, gồm phụ thuộc dài hạn, tác nhân tham gia ngầm và hiện tượng đồng tham chiếu. Đây là ba đặc trưng hiếm gặp hoặc ít nghiêm trọng hơn trong bài toán cấp câu nhưng lại mang tính bản chất đối với bài toán cấp văn bản. Phụ thuộc dài hạn xuất hiện khi các thành phần quan trọng của sự kiện cách xa nhau về vị trí trong tài liệu. Tác nhân ngầm xuất hiện khi một vai nghĩa không được diễn đạt trực tiếp mà phải suy ra từ ngữ cảnh hoặc tri thức nền. Đồng tham chiếu làm tăng độ khó vì mô hình phải nhận biết rằng nhiều biểu thức ngôn ngữ khác nhau thực chất cùng chỉ về một thực thể. Như vậy, DEE không chỉ là mở rộng độ dài đầu vào, mà còn đòi hỏi sự kết hợp giữa nhiều năng lực xử lý ngôn ngữ ở cấp diễn ngôn.

Sự trưởng thành của hướng nghiên cứu này được thể hiện rõ qua việc xuất hiện các bộ dữ liệu quy mô lớn như DocEE. (S. Li, Ji, & Han, 2021) cho rằng mặc dù trích xuất sự kiện ở cấp độ câu đã đạt nhiều kết quả tích cực, nhưng hình thức tồn tại tự nhiên của sự kiện vẫn là văn bản, không phải câu độc lập. Mục tiêu của DocEE là thúc đẩy sự phát triển của bài toán từ cấp câu lên cấp văn bản bằng cách cung cấp dữ liệu cho phép đánh giá khả năng phục hồi cấu trúc sự kiện trong bối cảnh các thành phần tham gia phân bố trên toàn tài liệu. Ý nghĩa của DocEE không chỉ ở số lượng mẫu dữ liệu mà còn ở chỗ nó xác lập một chuẩn đầu ra khác với SEE. Nếu trong SEE,

đầu ra thường là nhãn gắn với từ kích hoạt và đối số trong từng câu, thì trong DEE, đầu ra cần tiến gần hơn đến các bản ghi sự kiện hoàn chỉnh ở cấp tài liệu, nơi mỗi sự kiện được tái dựng từ nhiều đoạn thông tin rời rạc.

Bên cạnh hướng xây dựng dữ liệu, một số nghiên cứu đã mở rộng khung biểu diễn để thích ứng tốt hơn với bản chất phân tán của sự kiện trong văn bản. (Huang & Jia, 2021) xem toàn bộ tài liệu như một đồ thị quan hệ giữa câu và thực thể, trong đó mỗi sự kiện tương ứng với một cộng đồng câu. Cách tiếp cận này cho thấy sự kiện không nhất thiết phải gắn với một câu trung tâm duy nhất, mà có thể được hình thành từ một cụm câu liên kết với nhau thông qua các thực thể và quan hệ ngữ nghĩa chung. Từ góc nhìn này, văn bản không còn được xử lý như một chuỗi câu tuyến tính mà như một cấu trúc mạng, trong đó nhiều tín hiệu ngữ nghĩa phân tán cần được gom cụm và tổ chức lại để tạo thành các cấu trúc sự kiện mạch lạc. Đây là một hướng tiếp cận có giá trị vì nó phù hợp hơn với cách thông tin thường được tổ chức trong các văn bản dài và phức tạp.

(Han et al., 2022b) tiếp tục mở rộng bài toán khi xử lý các trường hợp tác nhân đa giá trị và quan hệ nhiều - nhiều giữa sự kiện và đối tượng tham gia. Đây là điểm rất quan trọng vì nhiều lược đồ truyền thống thường mặc định một vai nghĩa chỉ gắn với một thực thể hoặc một sự kiện chỉ có số lượng đối tượng tham gia hạn chế. Trong thực tế, một sự kiện có thể có nhiều thực thể cùng đảm nhiệm một vai trò, và một thực thể cũng có thể tham gia vào nhiều sự kiện trong cùng một văn bản. Khi dữ liệu được thiết kế để phản ánh hiện tượng này, mô hình phải giải quyết đồng thời ba bài toán: xác định ranh giới sự kiện, gán thực thể vào đúng vai nghĩa và phân biệt sự kiện nào đi với tập thực thể nào. Điều này cho thấy DEE đang dần chuyển từ một bài toán gán nhãn sang một bài toán tái cấu trúc tri thức có tính tổ hợp cao.

Từ chuỗi nghiên cứu nêu trên có thể thấy rằng sự phát triển từ SEE sang DEE phản ánh một thay đổi sâu sắc trong cách hiểu về sự kiện và về chính nhiệm vụ trích xuất sự kiện. Ở giai đoạn đầu, trích xuất sự kiện chủ yếu được xem là bài toán phát hiện các biểu thức ngôn ngữ mang tính chỉ báo trong phạm vi câu. Ở giai đoạn sau, đặc biệt với DEE, mục tiêu không còn dừng ở phát hiện từ kích hoạt hay đối số cục

bộ mà là tái dựng một biểu diễn sự kiện hoàn chỉnh ở cấp độ diễn ngôn. Do đó, sự thay đổi không chỉ nằm ở việc đầu vào dài hơn, mà còn ở chỗ đơn vị suy luận, đối tượng biểu diễn và tiêu chí đánh giá đều thay đổi.

Tuy vậy, DEE vẫn đối mặt với nhiều thách thức mở. Thứ nhất là vấn đề mô hình hóa phụ thuộc dài hạn trong văn bản dài, nhất là khi các kiến trúc hiện đại như Transformer gặp giới hạn về độ dài chuỗi và chi phí tính toán. Thứ hai là khó khăn trong xây dựng dữ liệu chú giải, bởi chú giải sự kiện ở cấp văn bản phức tạp hơn nhiều so với cấp câu, đòi hỏi người gán nhãn phải theo dõi đồng thời nhiều thực thể, nhiều quan hệ và nhiều lớp thông tin diễn ngôn. Thứ ba là vấn đề khái quát hóa miền dữ liệu. Phần lớn các bộ dữ liệu hiện có vẫn tập trung vào tin tức hoặc tài chính, trong khi các miền như y sinh, pháp lý hay truyền thông xã hội có đặc trưng ngôn ngữ và cấu trúc diễn đạt rất khác. Ngoài ra, hệ thống đánh giá cho DEE cũng chưa hoàn toàn thống nhất, bởi việc đo độ chính xác của từng vai nghĩa chưa đủ để phản ánh năng lực tái dựng cấu trúc sự kiện ở cấp tài liệu.

Nhìn tổng thể, có thể khẳng định rằng trích xuất sự kiện ở cấp độ văn bản không phải là một biến thể mở rộng đơn giản của trích xuất sự kiện ở cấp độ câu, mà là một hướng nghiên cứu có nền tảng lý thuyết và thực nghiệm riêng. Sự xuất hiện của các công trình như DCFEE, Doc2EDAG, RAMS, DocEE cùng các hướng tiếp cận dựa trên đồ thị và mô hình đa sự kiện cho thấy cộng đồng nghiên cứu đang dần chuyển từ tư duy xử lý cục bộ sang tư duy cấu trúc hóa tri thức ở cấp diễn ngôn. Đây là bước phát triển phù hợp với nhu cầu ứng dụng thực tiễn, nơi thông tin sự kiện hiếm khi xuất hiện trọn vẹn trong một câu và thường chỉ có thể được phục hồi thông qua việc tổng hợp các tín hiệu phân tán trên toàn văn bản.

2.2 Một số tập dữ liệu trong bài toán trích xuất sự kiện pháp lý

Đối với lĩnh vực trích xuất sự kiện pháp lý, tiến trình phát triển hiện nay vẫn còn tương đối mới và nguồn dữ liệu phục vụ nghiên cứu chưa thật sự phong phú. Phần lớn các tập dữ liệu hiện có được xây dựng cho tiếng Trung, đồng thời chủ yếu tiếp cận bài toán ở cấp độ câu. Điều này phản ánh đặc điểm chung của giai đoạn đầu trong nhiều hướng nghiên cứu xử lý ngôn ngữ: khi nguồn lực còn hạn chế, việc xác

định câu như đơn vị gán nhãn cơ bản giúp giảm chi phí chú giải, thuận lợi hơn cho việc thiết kế lược đồ và cho phép mô hình học được những mẫu biểu đạt tương đối rõ ràng. Tuy nhiên, trong miền pháp lý, cách tiếp cận này sớm bộc lộ hạn chế, bởi sự kiện trong bản án và các văn bản xét xử thường không xuất hiện đầy đủ trong một câu riêng lẻ, mà được triển khai qua nhiều câu, nhiều đoạn và gắn với mạch lập luận kéo dài trên toàn văn bản.

Một trong những công trình được xem là bước khởi đầu cho hướng nghiên cứu này là DivorceEE (C. Li, Sheng, Ge, & Luo, 2019). Tập dữ liệu này được xây dựng trên các vụ án ly hôn, với hơn 3.100 văn bản được gán nhãn phục vụ cho bài toán trích xuất sự kiện. Đóng góp quan trọng của công trình không chỉ nằm ở số lượng văn bản được chú giải, mà còn ở việc khẳng định tính khả thi của cách tiếp cận trích xuất sự kiện trong một miền pháp lý cụ thể. Việc lựa chọn án ly hôn là hợp lý, bởi đây là loại vụ án có cấu trúc tình huống tương đối rõ, thường xoay quanh các nội dung như quan hệ hôn nhân, tranh chấp tài sản, quyền nuôi con và các tình tiết liên quan giữa các bên đương sự. Nhờ vậy, sự kiện trong loại văn bản này có thể được tổ chức thành những khung vai nghĩa tương đối ổn định, tạo điều kiện thuận lợi cho việc xây dựng dữ liệu ban đầu.

Tuy nhiên, ý nghĩa của DivorceEE chủ yếu nằm ở vai trò mở đường hơn là cung cấp một lời giải toàn diện cho bài toán. Khi giới hạn trong một loại án cụ thể và tiếp cận ở cấp độ câu, tập dữ liệu này mới chỉ phản ánh được một phần của bức tranh tổng thể về sự kiện pháp lý. Trên thực tế, ngay cả trong các vụ án ly hôn, những thành phần quan trọng của một sự kiện như nguyên nhân phát sinh tranh chấp, diễn biến hành vi, yêu cầu của các bên, căn cứ xem xét và quyết định cuối cùng của tòa án thường được phân tán ở nhiều vị trí khác nhau trong văn bản. Vì vậy, nếu chỉ xử lý ở phạm vi câu, mô hình có thể nhận diện được một số biểu thức chỉ sự kiện, nhưng vẫn khó tái dựng đầy đủ mối liên hệ giữa các tình tiết và vai trò của từng chủ thể trong toàn bộ vụ việc.

Tiếp nối hướng nghiên cứu đó, CLEE công bố một tập dữ liệu trích xuất sự kiện dành cho các vụ án trộm cắp. Công trình này có đóng góp rõ ràng ở phương diện

chuyên biệt hóa miền dữ liệu, khi xác định loại sự kiện, các đối tượng tham gia và hệ thống vai nghĩa phù hợp riêng cho loại án này. Cách tiếp cận đó có ưu điểm là giúp lược đồ chú giải bám sát đặc trưng của hành vi phạm tội, từ đó tăng độ chính xác và tính nhất quán trong quá trình gán nhãn. Với các vụ án trộm cắp, những yếu tố như người thực hiện hành vi, tài sản bị chiếm đoạt, phương thức thực hiện, giá trị tài sản, thời điểm và địa điểm thường là các thành phần then chốt để mô tả sự kiện. Việc chuẩn hóa các yếu tố này trong một tập dữ liệu riêng cho thấy nghiên cứu trích xuất sự kiện pháp lý đã bắt đầu dịch chuyển từ những thử nghiệm khái quát sang các thiết kế có chiều sâu hơn theo từng loại án.

Dù vậy, CLEE cũng cho thấy một hạn chế thường gặp của các tập dữ liệu pháp lý giai đoạn đầu, đó là phạm vi bao phủ còn hẹp. Khi chỉ tập trung vào một số ít loại sự kiện trong một loại án cụ thể, khả năng khái quát hóa sang các bối cảnh pháp lý khác sẽ bị hạn chế. Trong thực tiễn xét xử, một bản án có thể đồng thời chứa nhiều nhóm sự kiện khác nhau, bao gồm hành vi vi phạm, hoàn cảnh phát sinh, hậu quả, tình tiết tăng nặng hoặc giảm nhẹ, cũng như các quyết định tố tụng và phán quyết của tòa án. Nếu dữ liệu chỉ bao phủ một phần nhỏ trong số đó, mô hình được huấn luyện từ dữ liệu này khó có thể phục vụ cho các hệ thống khai thác thông tin pháp lý ở quy mô rộng. Nói cách khác, CLEE cho thấy giá trị của hướng chuyên biệt hóa, nhưng đồng thời cũng đặt ra yêu cầu cần mở rộng lược đồ và mở rộng phạm vi sự kiện nếu muốn bài toán tiến gần hơn đến nhu cầu ứng dụng thực tế.

Một bước phát triển quan trọng hơn xuất hiện với LEVEN (Yao và cộng sự, 2022), thường được xem là bước nhảy đáng kể về nguồn dữ liệu cho nhiệm vụ phát hiện sự kiện pháp lý. Tập dữ liệu này được xây dựng từ các bản án hình sự tiếng Trung và có điểm nổi bật là thiết kế lược đồ không chỉ bao gồm sự kiện trung tâm, mà còn mô phỏng cả tiền sự kiện. Đây là đóng góp có ý nghĩa lớn về mặt học thuật. Trong nhiều văn bản pháp lý, đặc biệt là bản án hình sự, việc hiểu đúng vụ việc không thể chỉ dựa trên hành vi phạm tội chính, mà còn đòi hỏi nắm bắt được những tình tiết xuất hiện trước đó, chẳng hạn như nguyên nhân, điều kiện, bối cảnh chuẩn bị hoặc các hành vi dẫn tới sự kiện chính. Những yếu tố này nhiều khi giữ vai trò quan trọng

trong việc lý giải động cơ, đánh giá mức độ nghiêm trọng và xác định căn cứ áp dụng pháp luật, nhưng trước đó thường bị xem nhẹ trong các lược đồ trích xuất sự kiện.

Điểm đáng chú ý của LEVEN còn nằm ở việc chứng minh giá trị ứng dụng của thông tin sự kiện pháp lý đối với các bài toán liên quan. Tác giả chỉ ra rằng khi khai thác được thông tin sự kiện từ dữ liệu này, kết quả của các nhiệm vụ như dự đoán điều luật được viện dẫn và tìm kiếm vụ án tương đồng đều được cải thiện. Nhận định này có ý nghĩa quan trọng, bởi nó cho thấy trích xuất sự kiện pháp lý không chỉ là một bài toán độc lập mang tính học thuật, mà còn là tầng thông tin nền phục vụ cho nhiều hướng xử lý tri thức pháp lý khác. Một hệ thống có khả năng phục hồi các sự kiện trong bản án sẽ hỗ trợ hiệu quả cho việc tổ chức, tra cứu, so sánh và suy luận trên dữ liệu pháp luật.

Tuy nhiên, dù có bước tiến lớn về nguồn dữ liệu và lược đồ chú giải, LEVEN vẫn chủ yếu xác định bài toán ở cấp độ câu. Đây là giới hạn quan trọng cần được nhìn nhận rõ. Trong bản án hình sự, các thành phần của một sự kiện thường xuất hiện rải rác ở nhiều câu khác nhau: một câu mô tả hành vi, câu khác nêu hậu quả, câu tiếp theo làm rõ công cụ, động cơ hoặc vai trò của những người liên quan. Bên cạnh đó, cùng một bản án có thể chứa nhiều sự kiện nối tiếp nhau theo tiến trình vụ việc, từ chuẩn bị, thực hiện hành vi, phát hiện, điều tra cho tới xét xử và tuyên án. Nếu chỉ dừng ở cấp độ câu, mô hình khó có thể tái dựng toàn bộ chuỗi sự kiện cũng như mối liên hệ giữa chúng. Vì vậy, dù LEVEN là một bước tiến lớn, nó vẫn chưa giải quyết trọn vẹn bài toán trích xuất sự kiện ở cấp độ văn bản trong miền pháp lý.

Chính trên cơ sở đó, DLEE (Xian và cộng sự, 2024) được xem là một bước phát triển có tính chuyển hướng khi đề xuất tập dữ liệu trích xuất sự kiện pháp lý ở cấp độ văn bản đầu tiên. Ý nghĩa nổi bật của DLEE nằm ở việc thay đổi đơn vị xử lý từ câu sang toàn bộ tài liệu. Tác giả chỉ ra rằng trong bản án, sự kiện thường được trình bày trong những văn bản dài, với các đối tượng tham gia, tình tiết liên quan và quan hệ giữa các hành vi được phân bố trên nhiều câu. Do đó, việc chỉ dựa vào nguồn dữ liệu cấp câu khiến nghiên cứu trích xuất sự kiện pháp lý bị giới hạn về khả năng phản ánh đúng cấu trúc của vụ việc. DLEE được xây dựng nhằm khắc phục chính

điểm nghẽn này, đưa bài toán tiến gần hơn với cách thông tin pháp lý thực sự xuất hiện trong thực tế.

Một đóng góp quan trọng khác của DLEE là quy trình gán nhãn bán tự động. Trong miền pháp lý, chú giải ở cấp độ văn bản có chi phí rất lớn do văn bản dài, giàu chi tiết và đòi hỏi người gán nhãn phải theo dõi đồng thời nhiều thực thể, nhiều tình tiết và nhiều lớp quan hệ. Việc sử dụng quy trình bán tự động cho thấy nỗ lực cân bằng giữa hai mục tiêu thường khó đạt được đồng thời, đó là mở rộng quy mô dữ liệu và duy trì chất lượng chú giải. Đây là một hướng đi có tính thực tiễn cao, bởi nếu hoàn toàn dựa vào gán nhãn thủ công thì rất khó xây dựng được các tập dữ liệu đủ lớn cho bài toán cấp văn bản. Mặt khác, nếu quá phụ thuộc vào quy trình tự động thì nguy cơ sai lệch lược đồ và giảm độ tin cậy của dữ liệu lại tăng lên. DLEE cho thấy một nỗ lực dung hòa hai yêu cầu này trong bối cảnh đặc thù của văn bản pháp lý.

Tuy vậy, kết quả thực nghiệm trên DLEE cũng cho thấy trích xuất sự kiện pháp lý ở cấp độ văn bản vẫn là một bài toán mở với nhiều thách thức chưa được giải quyết. Khó khăn trước hết đến từ độ dài văn bản và mật độ thông tin cao của bản án. Ngoài ra, các sự kiện trong văn bản pháp lý không tồn tại tách rời mà thường gắn với nhau trong một chuỗi lập luận chặt chẽ, nơi diễn biến của sự kiện trước có thể là điều kiện để hiểu sự kiện sau. Hiện tượng đồng quy chiếu, cách diễn đạt mang tính quy phạm, sự đan xen giữa mô tả sự kiện thực tế và diễn giải pháp lý của tòa án cũng làm tăng độ khó cho việc mô hình hóa. Vì vậy, việc chuyển từ cấp độ câu sang cấp độ văn bản không chỉ là mở rộng độ dài đầu vào, mà thực chất là thay đổi bản chất của bài toán theo hướng phức tạp hơn nhiều.

Nhìn tổng thể, tiến trình phát triển của các tập dữ liệu pháp lý cho thấy một quỹ đạo tương đối rõ. DivorceEE đặt nền móng ban đầu bằng cách chứng minh tính khả thi của việc xây dựng dữ liệu trong một loại án cụ thể. CLEE tiếp tục đào sâu theo hướng chuyên biệt hóa lược đồ cho một nhóm vụ án nhất định. LEVEN mở rộng đáng kể quy mô và làm giàu cấu trúc biểu diễn bằng việc đưa thêm tiền sự kiện vào khung chú giải, đồng thời chứng minh giá trị ứng dụng của thông tin sự kiện đối với các nhiệm vụ pháp lý khác. Sau đó, DLEE đánh dấu bước chuyển quan trọng từ cách

tiếp cận ở cấp độ câu sang cách tiếp cận ở cấp độ văn bản. Chuỗi phát triển này cho thấy lĩnh vực trích xuất sự kiện pháp lý đang dần dịch chuyển từ những thiết kế đơn giản, cục bộ và hẹp về phạm vi sang những mô hình dữ liệu phản ánh sát hơn bản chất của văn bản pháp luật.

Từ góc nhìn này, có thể thấy khoảng trống nghiên cứu hiện nay không còn nằm ở việc chứng minh xem trích xuất sự kiện pháp lý có khả thi hay không, mà nằm ở việc xây dựng các nguồn dữ liệu và phương pháp đủ mạnh để xử lý được tính phức tạp của văn bản pháp lý dài. Đây cũng chính là cơ sở quan trọng để phát triển các tập dữ liệu mới trong những ngôn ngữ còn hạn chế tài nguyên, trong đó có tiếng Việt. Khi đối chiếu với tiến trình của tiếng Trung, có thể nhận thấy rằng việc phát triển dữ liệu ở cấp độ văn bản cho miền pháp lý là bước tiếp theo mang tính tất yếu nếu mục tiêu là xây dựng các hệ thống có khả năng hiểu vụ việc ở mức cấu trúc, thay vì chỉ nhận diện rời rạc các biểu thức sự kiện trong từng câu.

2.3 Một số tập dữ liệu trích xuất sự kiện trên miền ngôn ngữ tiếng Việt

Các nghiên cứu về trích xuất sự kiện trên miền ngôn ngữ tiếng Việt cũng được thúc đẩy, trong đó nổi bật với hai tập dữ liệu BKEE (Nguyen, Tran, Luu, Nguyen, & Nguyen, 2024) và VHE (Hoang, Nguyen, & Dinh, 2024). BKEE được xây dựng trên miền kinh doanh và tài chính, tập trung vào các dạng sự kiện thường xuất hiện trong môi trường hoạt động của doanh nghiệp, tổ chức và cá nhân. Việc lựa chọn miền này là hợp lý cả về mặt học thuật lẫn ứng dụng. Về mặt học thuật, văn bản kinh doanh và tài chính chứa nhiều cấu trúc sự kiện có tính quy chuẩn cao, chẳng hạn như giao dịch, ký kết hợp đồng, chuyển nhượng, đầu tư, hợp tác hoặc các thay đổi liên quan đến tổ chức. Các sự kiện này thường gắn với những vai nghĩa tương đối ổn định như bên tham gia, đối tượng giao dịch, giá trị, thời điểm và địa điểm. Nhờ đó, việc xây dựng tập dữ liệu và thiết kế lược đồ chú giải có thể đạt được mức độ nhất quán tương đối cao. Về mặt ứng dụng, đây là nhóm sự kiện có giá trị thực tiễn lớn trong các hệ thống theo dõi thị trường, phân tích doanh nghiệp, tổng hợp tin tức tài chính và hỗ trợ ra quyết định. Vì vậy, BKEE không chỉ bổ sung nguồn ngữ liệu cho tiếng Việt mà còn

cho thấy hướng phát triển gắn chặt giữa nghiên cứu học thuật với nhu cầu xử lý thông tin trong bối cảnh thực tế.

Tuy nhiên, đóng góp của BKEE không nên chỉ được nhìn nhận ở phương diện mở rộng dữ liệu cho một lĩnh vực cụ thể. Quan trọng hơn, tập dữ liệu này phản ánh giai đoạn đầu của nghiên cứu trích xuất sự kiện tiếng Việt, khi bài toán chủ yếu được tổ chức ở cấp độ câu. Trong khuôn khổ đó, mỗi câu thường được xem là đơn vị cơ bản để nhận diện từ biểu hiện sự kiện, xác định loại sự kiện và gán các thành phần tham gia. Cách tiếp cận này phù hợp với điều kiện nguồn lực còn hạn chế, bởi nó giúp đơn giản hóa quá trình chú giải và giảm độ phức tạp của mô hình. Tuy vậy, giống như xu hướng đã diễn ra ở các ngôn ngữ khác, việc giới hạn ở cấp độ câu cũng đồng thời đặt ra một giới hạn về khả năng phản ánh đầy đủ bản chất của sự kiện trong văn bản tự nhiên. Trong thực tế, đặc biệt ở miền kinh doanh và tài chính, một giao dịch hay một quan hệ hợp đồng thường không được mô tả trọn vẹn trong một câu duy nhất. Các thành phần của cùng một sự kiện có thể phân tán ở nhiều câu khác nhau, trong khi những câu riêng lẻ chỉ cung cấp từng phần của bức tranh tổng thể. Do đó, BKEE có vai trò quan trọng như một bước khởi đầu, nhưng đồng thời cũng cho thấy nhu cầu cần tiếp tục mở rộng nghiên cứu sang cấp độ cao hơn.

Nếu BKEE đại diện cho hướng phát triển theo miền kinh doanh và tài chính, thì VHE lại mở ra một hướng đi đáng chú ý khác khi lựa chọn chủ đề lịch sử làm nền tảng xây dựng dữ liệu. Đây là một lựa chọn có giá trị cả về mặt khoa học lẫn giá trị tư liệu. Văn bản lịch sử có những đặc điểm rất khác so với văn bản tin tức đương đại hoặc văn bản hành chính thông thường. Nội dung lịch sử thường gắn với các sự kiện kéo dài trong thời gian, có nhiều lực lượng tham gia, nhiều lớp nguyên nhân và hệ quả, đồng thời được diễn đạt trong phong cách tường thuật có độ nén thông tin cao. Các sự kiện chiến tranh, phong trào xã hội hay các mốc biến chuyển quan trọng trong tiến trình lịch sử thường không chỉ là những hành động đơn lẻ, mà là những cấu trúc sự kiện phức hợp, có thể bao gồm nhiều hành động thành phần, nhiều chủ thể và nhiều mối liên hệ nối tiếp nhau. Việc phát triển một tập dữ liệu như VHE vì vậy cho

thấy nỗ lực mở rộng phạm vi ứng dụng của bài toán trích xuất sự kiện sang những loại văn bản có đặc trưng ngôn ngữ và tri thức chuyên biệt hơn.

Từ góc độ nghiên cứu, VHE có ý nghĩa đặc biệt ở chỗ nó góp phần chứng minh rằng trích xuất sự kiện trong tiếng Việt không nhất thiết chỉ nên tập trung vào các miền dữ liệu hiện đại, ngắn và có cấu trúc tương đối rõ ràng. Ngược lại, các tài liệu lịch sử đặt ra nhiều yêu cầu cao hơn đối với mô hình, chẳng hạn như khả năng xử lý tên gọi lịch sử, quan hệ giữa các lực lượng, mốc thời gian phức tạp, cũng như cách diễn đạt giàu tính tường thuật và đôi khi mang tính khái quát. Điều này có thể xem là một bước tiến quan trọng trong việc nâng cao độ khó và độ phong phú của nguồn ngữ liệu tiếng Việt. Đồng thời, VHE cũng gợi mở khả năng ứng dụng bài toán trích xuất sự kiện vào các nhiệm vụ lớn hơn như số hóa tư liệu lịch sử, xây dựng kho tri thức lịch sử, hỗ trợ tra cứu hoặc tóm lược diễn biến sự kiện trong văn bản lịch sử.

Mặc dù vậy, điểm chung giữa BKEE và VHE là cả hai vẫn chủ yếu được thiết kế cho trích xuất sự kiện ở cấp độ câu. Điều này phản ánh đúng hiện trạng phát triển của lĩnh vực đối với tiếng Việt: nguồn lực dữ liệu mới chỉ ở giai đoạn đầu, ưu tiên những bài toán có phạm vi chú giải hẹp hơn và dễ kiểm soát hơn. Cách tiếp cận này có ý nghĩa thực tiễn rõ ràng, bởi việc chú giải ở cấp độ câu ít tốn kém hơn, dễ thống nhất hơn giữa những người gán nhãn và phù hợp với năng lực của nhiều mô hình hiện nay. Tuy nhiên, khi đặt trong bối cảnh phát triển chung của lĩnh vực, có thể thấy đây mới chỉ là bước nền tảng. Những hạn chế đã được chỉ ra đối với nghiên cứu ở các ngôn ngữ khác cũng xuất hiện tương tự đối với tiếng Việt: một sự kiện trong văn bản thực tế hiếm khi được biểu đạt trọn vẹn trong một câu; thông tin về chủ thể, đối tượng, căn cứ, hậu quả hoặc diễn biến có thể phân bố trên nhiều câu; các thực thể có thể được nhắc lại thông qua hình thức thay thế hoặc liên kết đồng quy chiếu. Vì thế, nếu chỉ dừng ở cấp độ câu, hệ thống khó có thể khôi phục đầy đủ cấu trúc sự kiện như nó tồn tại trong văn bản.

Khoảng trống này đặc biệt rõ khi xét đến miền pháp lý. Văn bản pháp lý có mật độ thông tin cao, cấu trúc lập luận chặt chẽ và thường tổ chức nội dung theo mạch diễn giải kéo dài qua nhiều câu, nhiều đoạn. Trong một văn bản pháp lý, một sự kiện

không chỉ bao gồm hành vi trung tâm mà còn gắn với hàng loạt thành phần khác như chủ thể thực hiện, chủ thể bị tác động, căn cứ pháp lý, thời điểm, địa điểm, hậu quả pháp lý và các tình tiết liên quan. Nhiều thành phần trong số này không xuất hiện tập trung ở một câu mà được phân bổ dọc theo toàn bộ văn bản. Hơn nữa, cùng một văn bản pháp lý có thể đồng thời chứa nhiều sự kiện có liên hệ với nhau, trong đó kết quả của sự kiện trước có thể trở thành điều kiện hoặc căn cứ cho sự kiện sau. Đặc điểm này làm cho bài toán trích xuất sự kiện trên văn bản pháp lý trở nên phức tạp hơn đáng kể so với các văn bản ngắn và mang tính tường thuật đơn giản.

Trên cơ sở đó, việc xây dựng VLEX có thể được xem là một bước phát triển tiếp theo nhằm khắc phục giới hạn hiện tại của nghiên cứu trích xuất sự kiện tiếng Việt. Điểm mới cốt lõi của hướng này nằm ở việc chuyển trọng tâm từ cấp độ câu sang cấp độ văn bản, đồng thời lựa chọn miền pháp lý làm đối tượng nghiên cứu. Đây là một lựa chọn có tính chiến lược. Thứ nhất, miền pháp lý là một trong những miền có nhu cầu cao về khai thác thông tin cấu trúc, bởi văn bản pháp lý thường dài, phức tạp và khó xử lý bằng phương pháp thủ công. Thứ hai, cấu trúc sự kiện trong văn bản pháp lý có tính chuẩn tắc và có thể được mô hình hóa thành các khung vai nghĩa rõ ràng, tạo điều kiện cho việc xây dựng lược đồ chú giải có cơ sở. Thứ ba, nếu được phát triển đầy đủ, một tập dữ liệu như VLEX không chỉ phục vụ bài toán trích xuất sự kiện, mà còn có thể hỗ trợ các hướng nghiên cứu liên quan như tìm kiếm thông tin pháp lý, hỏi đáp pháp lý, tóm lược văn bản pháp luật và xây dựng cơ sở tri thức pháp lý tự động.

CHƯƠNG 3. CƠ SỞ LÝ THUYẾT

3.1 Mô hình hóa bài toán

Cho một văn bản *D*, bao gồm tập hợp các câu $\{s_1, s_2, \dots, s_{|D|}\}$, với $|D|$ là số câu trong văn bản *D*, trong đó mỗi câu là một chuỗi các từ $\{w_1, w_2, \dots, w_{|s|}\}$ với $|s|$ là số từ trong câu *s*. Mục tiêu của bài toán trích xuất sự kiện ở cấp độ văn bản là suy luận có cấu trúc về các sự kiện được nêu trong toàn văn bản, bao gồm việc nhận dạng loại sự kiện và xác định đầy đủ các thành phần tham gia tương ứng, trong khi vẫn bảo toàn đặc trưng rằng thông tin liên quan có thể phân tán trên nhiều câu và một văn bản có thể đồng thời chứa nhiều sự kiện. Bài toán thường được phân rã thành hai tác vụ con có quan hệ chặt chẽ là phân loại sự kiện và trích xuất đối số:

Đối với phân loại sự kiện, mô hình cần dự đoán tập các loại sự kiện xuất hiện trong văn bản *D* dựa trên một danh mục loại sự kiện đã được định nghĩa trước. Trong thiết lập dựa trên từ kích hoạt, các biểu thức kích hoạt đóng vai trò giúp khoanh vùng sự xuất hiện của sự kiện và hỗ trợ quyết định loại. Do đặc trưng đa sự kiện, một văn bản có thể chứa đồng thời nhiều loại sự kiện khác nhau hoặc nhiều lần xuất hiện của cùng một loại, nên bài toán này thường được mô hình hóa như một nhiệm vụ phân loại đa nhãn, trong đó đầu ra là một tập nhãn thay vì một nhãn đơn.

Đối với trích xuất đối số, mô hình cần phát hiện tất cả các đoạn văn bản tương ứng với đối số xuất hiện trong *D*, sau đó gán cho mỗi đối số một vai trò ngữ nghĩa thuộc một tập vai trò đã được quy định bởi lược đồ sự kiện; quá trình này không chỉ đòi hỏi nhận diện đúng biên của đối số mà còn yêu cầu phân loại đúng vai trò trong ngữ cảnh của từng sự kiện, đặc biệt trong trường hợp nhiều sự kiện cùng tồn tại khiến cùng một thực thể có thể đảm nhiệm các vai trò khác nhau ở các sự kiện khác nhau.

3.2 Sự kiện

Sự kiện có thể được hiểu là một sự việc hoặc hiện tượng xảy ra trong thế giới thực, được quan sát và ghi nhận, trong đó tồn tại sự tham gia của các thành phần nhất định và được giữ trong một bối cảnh cụ thể về thời gian và không gian. Trong khuôn khổ bài toán trích xuất sự kiện, hai yếu tố trung tâm cần được xem xét đồng thời là

từ kích hoạt và các thành phần tham gia của sự kiện. Các thành phần tham gia bao gồm những đối tượng được đề cập trong văn bản có vai trò trực tiếp hoặc gián tiếp đối với sự kiện, với phạm vi rất rộng, có thể là con người, tổ chức, đồ vật, công trình, phương tiện, địa danh, công cụ hoặc bất kỳ thực thể nào được văn bản định danh và đặt vào quan hệ hành động hay trạng thái liên quan đến sự kiện. Bên cạnh đó, trong nhiều trường hợp, thông tin góp phần cấu thành ý nghĩa sự kiện không nhất thiết xuất hiện dưới dạng một thực thể định danh, mà có thể là các mô tả về mức độ, trạng thái, kết quả, thiệt hại, số lượng, giá trị, phương thức hoặc các đặc tính khác gắn với sự kiện; những yếu tố này tham gia vào việc hoàn chỉnh cấu trúc ngữ nghĩa của sự kiện và thường được gọi là thuộc tính. Trên phương diện mô tả chính thức, cả thực thể và thuộc tính đều được quy về cùng một lớp khái niệm là các đối số của sự kiện, phản ánh tập thông tin cần thiết để mô tả đầy đủ một lần xuất hiện của sự kiện trong văn bản.

Song song với đối số, từ kích hoạt sự kiện là đơn vị ngôn ngữ đóng vai trò thể hiện ngữ nghĩa một cách trực tiếp và rõ ràng nhất cách sự kiện được biểu đạt, qua đó giúp khoanh vùng đoạn văn có liên quan và định hướng việc xác định các đối số đi kèm. Từ kích hoạt thường là yếu tố giàu thông tin nhất để phân biệt các loại sự kiện, nhưng không bị giới hạn ở phạm trù động từ; trong văn bản pháp lý, từ kích hoạt có thể xuất hiện dưới dạng danh từ, cụm danh từ, miễn là thể hiện đúng đặc trưng cốt lõi của sự kiện cần trích xuất. Ở cấp độ văn bản, hiện tượng đa sự kiện được hiểu là sự đồng thời xuất hiện của nhiều sự kiện trong cùng một tài liệu, có thể thuộc các loại khác nhau hoặc cùng một loại, và mỗi sự kiện về nguyên tắc đều có một hoặc một tập điểm thể hiện ngữ nghĩa riêng để phân biệt với các sự kiện còn lại, có thể tham khảo thêm ví dụ ở Bảng 3.1. Tuy nhiên, cần phân biệt rõ đa sự kiện với trường hợp một sự kiện được diễn đạt bằng nhiều từ kích hoạt hoặc nhiều biến thể diễn đạt trong các câu khác nhau, bởi nếu nhầm lẫn giữa hai hiện tượng này sẽ dẫn đến việc tách sai số lượng sự kiện hoặc gán nhãn thừa, từ đó làm suy giảm tính nhất quán và chất lượng cuối cùng của tập dữ liệu.

Bảng 3.1 Ví dụ về việc trích xuất sự kiện từ mẫu văn bản đa sự kiện trong VLEX

<table>
<tr><td colspan="3">Từ cuối tháng 01 năm 2022 đến cuối tháng 3 năm 2022, trên địa bàn xã Trường Đông, thị xã Hòa Thành, tỉnh Tây Ninh, Trần Phước T đã có hành vi đe dọa sẽ dùng vũ lực để buộc anh Dương Tấn N là trưởng đoàn Hội chợ “Khởi My” đưa tiền bảo kê mỗi đêm là 1.000.000 đồng. Tổng số tiền T chiếm đoạt của anh N là 60.000.000 đồng.
Lúc 19 giờ 30 phút ngày 13/02/2022, tại Hội chợ “Khởi My” thuộc ấp Trường Lưu, xã Trường Đông, thị xã Hòa Thành, tỉnh Tây Ninh, tuy không có mâu thuẫn gì, nhưng Trần Phước T, Hà Thanh S, Trương Vũ C và Trần Hữu D đã dùng cây ba khúc bằng kim loại, cờ lê (khoá loại 24) bằng kim loại, chai nước ngọt bằng thuỷ tinh là hung khí nguy hiểm đánh gây thương tích cho các bị hại Huỳnh Nguyễn Tấn T tổn thương cơ thể 10%, Nguyễn Anh T tổn thương cơ thể 01%.</td></tr>
<tr><th>Cưỡng đoạt tài sản</th><th>Cố ý gây thương tích</th><th>Cố ý gây thương tích</th></tr>
<tr><td>từ kích hoạt: đe dọa sẽ dùng vũ lực</td><td>từ kích hoạt: gây thương tích</td><td>từ kích hoạt: gây thương tích</td></tr>
<tr><td>thời gian: Từ cuối tháng 01 năm 2022 đến cuối tháng 3 năm 2022
địa điểm: xã Trường Đông, thị xã Hòa Thành, tỉnh Tây Ninh
bị cáo: Trần Phước T
nạn nhân: Dương Tấn N
tài sản: tiền
giá trị tài sản: 60.000.000 đồng
phương tiện gây án: không có</td><td>thời gian: 19 giờ 30 phút ngày 13/02/2022
địa điểm: Hội chợ “Khởi My” thuộc ấp Trường Lưu, xã Trường Đông, thị xã Hòa Thành, tỉnh Tây Ninh
bị cáo: Trần Phước T, Hà Thanh S, Trương Vũ C, Trần Hữu D
nạn nhân: Huỳnh Nguyễn Tấn T
vùng thương tổn: cơ thể</td><td>thời gian: 19 giờ 30 phút ngày 13/02/2022
địa điểm: Hội chợ “Khởi My” thuộc ấp Trường Lưu, xã Trường Đông, thị xã Hòa Thành, tỉnh Tây Ninh
bị cáo: Trần Phước T, Hà Thanh S, Trương Vũ C, Trần Hữu D
nạn nhân: Nguyễn Anh T
vùng thương tổn: cơ thể
mức độ thương tổn: 01%</td></tr>
</table>

công cụ gây án: không có **hành vi sau vụ án:** không có	**mức độ thương tổn:** 10% **công cụ gây án:** cây ba khúc bằng kim loại, cờ lê (khoá loại 24) bằng kim loại, chai nước ngọt bằng thuỷ tinh **hành vi sau vụ án:** không có	**công cụ gây án:** cây ba khúc bằng kim loại, cờ lê (khoá loại 24) bằng kim loại, chai nước ngọt bằng thuỷ tinh **hành vi sau vụ án:** không có

3.3 Lược đồ sự kiện

Lược đồ sự kiện (event schema) được xem như một đặc tả khái niệm có cấu trúc nhằm chuẩn hóa cách biểu diễn sự kiện trong dữ liệu, qua đó bảo đảm rằng các hệ thống khác nhau có thể nhận diện, so sánh và đánh giá kết quả trên cùng một nền tảng biểu diễn. Về bản chất, lược đồ quy định trước tập loại sự kiện cần trích xuất và đối với mỗi loại, tập hợp vai trò của đối số cần điền để mô tả đầy đủ một lần xuất hiện của sự kiện trong văn bản, đồng thời cho phép mô hình hóa những thông tin mang tính thuộc tính như thời gian, địa điểm, mức độ thiệt hại, kết quả hay trạng thái liên quan.

Có nhiều hướng tiếp cận hiện đại, đặc biệt ở cấp độ văn bản, sự kiện thường được biểu diễn theo dạng bản ghi hoặc bảng điền thông tin, trong đó mỗi bản ghi tương ứng với một thể hiện cụ thể của sự kiện và mỗi trường tương ứng với một vai trò, giúp nắm bắt được đặc trưng rằng thông tin về cùng một sự kiện có thể phân tán trên nhiều câu và một tài liệu có thể chứa đồng thời nhiều sự kiện. Một yếu tố quan trọng khi phân tích lược đồ là lựa chọn giữa thiết lập dựa trên từ kích hoạt và thiết lập không phụ thuộc từ kích hoạt, bởi từ kích hoạt có thể đóng vai trò thể hiện ngữ nghĩa để khoanh vùng vị trí biểu đạt sự kiện và hỗ trợ liên kết các đối số, nhưng cũng có thể gây nhiễu trong văn bản dài hoặc khi diễn đạt gián tiếp khiến việc quy ước từ kích hoạt trở nên khó nhất quán, vì vậy có những thiết kế ưu tiên biểu diễn sự kiện

như một cấu trúc bảng để điền vào mà không yêu cầu gán nhãn từ kích hoạt một cách tường minh.

Một góc độ khác là độ mịn của vai trò đối số, trong đó lược đồ càng chi tiết thì khả năng biểu đạt ngữ nghĩa càng cao nhưng đồng thời làm tăng độ khó phân biệt vai trò và yêu cầu cao hơn về tính nhất quán trong diễn giải, nhất là khi văn bản có nhiều thực thể đồng thời tham gia và có nhiều chi tiết bối cảnh. Cuối cùng, lược đồ hiệu quả cần xử lý rõ các hiện tượng đa sự kiện và đa trị đối số, nghĩa là phải làm rõ khi nào một văn bản chứa nhiều bản ghi sự kiện cùng loại, khi nào một vai được phép có nhiều giá trị trong cùng một bản ghi, và tiêu chí tối thiểu để xem một bản ghi là hợp lệ, bởi các quyết định này ảnh hưởng trực tiếp đến độ ổn định của dữ liệu và năng lực tổng quát hóa của mô hình trên các văn bản thực tế.

3.4 Phương pháp đánh giá Cohen's kappa

Phương pháp Cohen's kappa thường được sử dụng ở các bài toán có giai đoạn gán nhãn như một chỉ số đo mức độ đồng thuận giữa hai người gán nhãn theo hướng đã hiệu chỉnh ảnh hưởng của sự trùng khớp ngẫu nhiên, qua đó phản ánh tốt hơn mức độ nhất quán thực chất của quy trình gán nhãn so với việc chỉ báo cáo tỷ lệ trùng khớp thô (McHugh, 2012). Phương pháp Cohen's kappa được xác định từ hai đại lượng là đồng thuận quan sát được và đồng thuận kỳ vọng theo ngẫu nhiên, trong đó đồng thuận kỳ vọng được tính từ phân phối biên của các nhãn, nên kappa giúp giảm thiên lệch khi bài toán có nhiều nhãn hoặc khi phân bố nhãn mất cân bằng; đồng thời, trong thiết lập có nhiều hơn hai người gán nhãn, thực hành phổ biến là tính kappa theo từng cặp rồi tổng hợp để thu được một đại lượng đại diện cho chất lượng đồng thuận của cả nhóm.

Công thức Cohen's kappa có thể viết như sau:

$$\kappa = \frac{p_o - p_e}{1 - p_e} \tag{3.1}$$

Trong đó: κ là giá trị cohen's kappa, p_o là xác suất đồng thuận quan sát còn p_e là xác suất đồng thuận kỳ vọng do ngẫu nhiên.

Trong trường hợp có m người gán nhãn và ta tính kappa theo từng cặp, sau đó tính trung bình của các kappa trên như công thức (3.2) :

$$\bar{\kappa} = \frac{2}{m(m-1)} \sum_{i<j} \kappa_{i,j} \tag{3.2}$$

với $\kappa_{i,j}$ là kappa giữa người gán nhãn i và người gán nhãn j, $\bar{\kappa}$ đại diện cho kappa trung bình của tất cả người gán nhãn.

Kappa càng tiến gần 1 thì mức đồng thuận càng cao và càng vượt xa mức có thể đạt được do ngẫu nhiên, trong khi các giá trị thấp gợi ý hoặc hướng dẫn gán nhãn chưa đủ rõ, hoặc người gán nhãn chưa được huấn luyện thống nhất, hoặc bản thân nhiệm vụ chứa nhiều trường hợp mơ hồ. Vì vậy, kappa thường được dùng như tín hiệu để quyết định có cần điều chỉnh hướng dẫn, tăng vòng rà soát, hay tái huấn luyện người gán nhãn nhằm tránh đánh đồng các nhóm hiện tượng có độ phức tạp không đồng nhất và giúp các quyết định về rà soát hay tái gán nhãn bám sát đặc thù của từng loại sự kiện hơn là dựa trên một con số ngưỡng duy nhất.

3.5 Một số mô hình nổi bật trong bài toán trích xuất sự kiện ở cấp độ văn bản

Để đánh giá tập dữ liệu cũng như xây dựng tiêu chuẩn đánh giá ban đầu, chúng tôi tiến hành tìm hiểu và nghiên cứu một số mô hình trích xuất sự kiện ở cấp độ văn bản nổi bật nhằm hiểu cấu trúc dữ liệu tiêu chuẩn trong bài toán này.

3.5.1 Document-level Chinese Financial Event Extraction (DCFEE)

DCFEE là một mô hình trích xuất sự kiện ở cấp độ văn bản được thiết kế theo hướng pipeline, chia quá trình trích xuất thành các bước riêng biệt, bao gồm phân loại sự kiện, nhận diện các đối số, và cuối cùng là hợp nhất các đối số vào bản ghi sự kiện. Mô hình này dựa vào một chuỗi các mô-đun xử lý tuần tự, nơi đầu ra của mỗi bước sẽ là đầu vào cho bước tiếp theo. Trong quá trình thực hiện, DCFEE nhận diện các sự kiện trong văn bản, phân loại chúng và xác định các đối số tham gia vào từng sự kiện, sau đó thực hiện các bước ghép nối và kết hợp các đối số đã nhận diện vào các sự kiện tương ứng. Một đặc điểm quan trọng của DCFEE là việc sử dụng phương

pháp gán nhãn tự động dựa trên distant supervision, tức là mô hình được huấn luyện từ các nguồn dữ liệu không gán nhãn, thông qua việc liên kết các sự kiện trong dữ liệu gốc với các nhãn được gán theo các đặc trưng ngữ nghĩa nhất định, có thể xem chi tiết ở Hình 3.1.

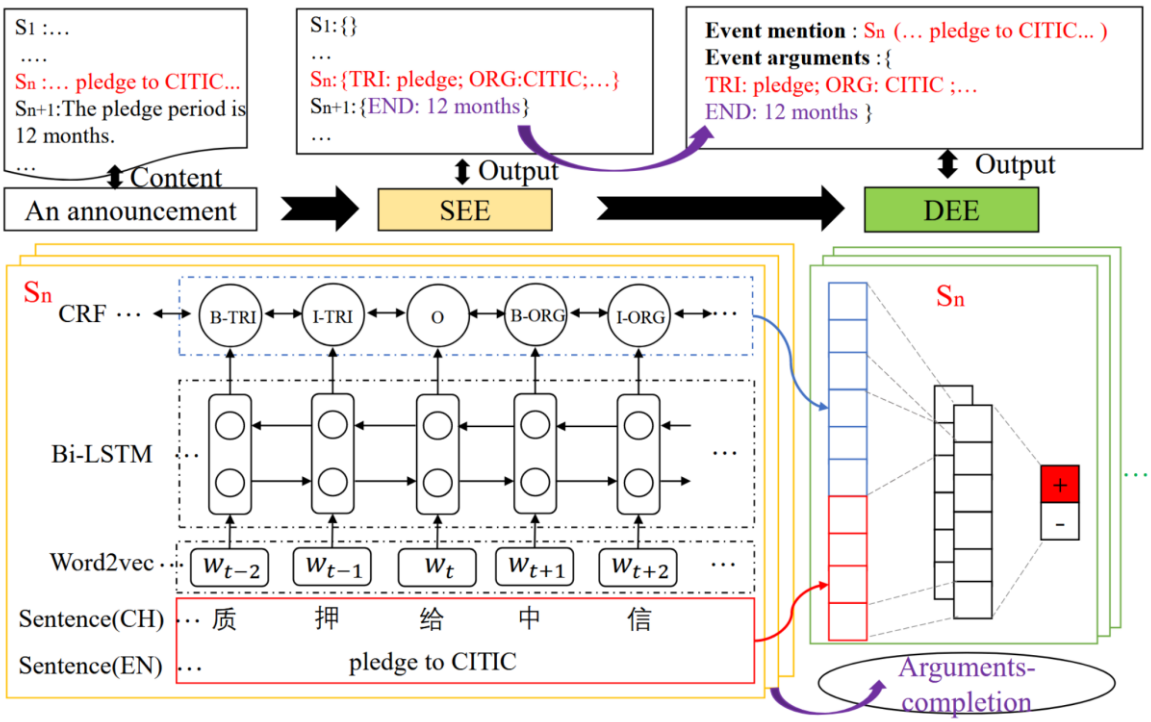

Hình 3.1 Kiến trúc mô hình DCFEE
(Nguồn: (Yang et al., 2018))

Mặc dù có ưu điểm về khả năng xử lý dữ liệu lớn và chi phí thấp nhờ việc tự động hóa quy trình gán nhãn, phương pháp này cũng bộc lộ những hạn chế, đặc biệt là trong việc kiểm soát sự chính xác trong các bước xử lý tuần tự. Nếu một bước trong chuỗi xử lý gặp phải sai sót hoặc không chính xác, sai lệch này có thể lan truyền sang các bước sau, dẫn đến mất tính chính xác trong kết quả cuối cùng. Điều này đặc biệt rõ rệt khi xử lý các văn bản pháp lý dài và phức tạp, nơi thông tin về các sự kiện thường bị phân tán và có thể gây khó khăn trong việc liên kết các đối số và sự kiện.

3.5.2 Document to Event Directed Acyclic Graph (Doc2EDAG)

Doc2EDAG là một phương pháp tiếp cận end-to-end trong trích xuất sự kiện cấp văn bản, nơi sự kiện được mô hình hóa dưới dạng các bản ghi đầy đủ, bao gồm các loại sự kiện và đối số tham gia. Điểm đặc biệt của Doc2EDAG là việc sử dụng đồ thị không chu trình (DAG) để tổ chức các đối số và sự kiện, trong đó các đối số và vai trò của chúng được kết nối qua các cạnh của đồ thị. Cơ chế giải mã của Doc2EDAG không chỉ phân tích mối quan hệ giữa các đối số và sự kiện trong từng câu mà còn nắm bắt được các tương tác toàn cục giữa các đối số và sự kiện trong toàn bộ văn bản, qua đó hỗ trợ việc khôi phục đúng sự kiện và phân bổ đối số một cách chính xác. Mô hình này sử dụng các module chú ý (attention modules) để học các liên kết ngữ nghĩa giữa các đối số và các sự kiện, giúp cải thiện khả năng trích xuất trong các văn bản dài, nơi các đối số có thể phân tán và không được gắn kết ngay lập tức với sự kiện mà chúng tham gia, chi tiết xem ở Hình 3.2. Điều này giúp giải quyết vấn đề một số mô hình cơ sở không thể xử lý khi sự kiện và đối số không nằm trong cùng một câu hoặc đoạn văn. Tuy nhiên, Doc2EDAG cũng yêu cầu một bộ nhớ tính toán lớn hơn và cơ chế tối ưu hóa đồ thị mạnh mẽ, vì số lượng đối số và mối quan hệ giữa chúng có thể tăng lên nhanh chóng khi xử lý các văn bản dài và phức tạp, tạo ra thách thức về chi phí tính toán và hiệu suất của mô hình.

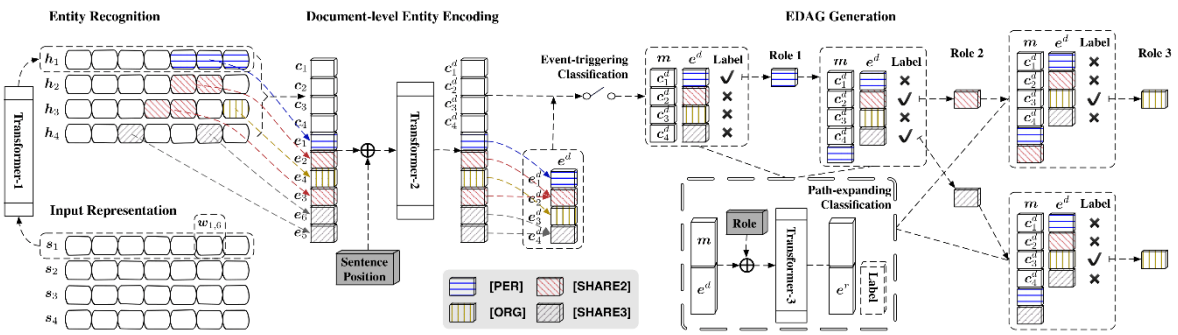

Hình 3.2 Kiến trúc mô hình Doc2EDAG

(Nguồn: (Zheng et al., 2019))

3.5.3 Graph-based Interaction Model with a Tracker (GIT)

GIT áp dụng mô hình đồ thị dị thể (heterogeneous graph) để mô hình hóa sự kiện trong văn bản, nơi các câu được coi là các nút trong đồ thị và các mối quan hệ giữa các câu và các thực thể được biểu thị dưới dạng các cạnh đồ thị. Phương pháp này sử dụng một cơ chế mô hình hóa tương tác toàn cục, trong đó các nút và các cạnh có thể trao đổi thông tin qua các lớp chuyển tiếp (transformer layers), giúp mô hình nắm bắt được mối quan hệ giữa các sự kiện và đối số một cách toàn diện. GIT đặc biệt mạnh mẽ trong việc xử lý các mối quan hệ phụ thuộc giữa các sự kiện và đối số xuyên suốt văn bản, một vấn đề phổ biến trong trích xuất sự kiện ở cấp độ văn bản, nơi thông tin về các sự kiện và đối số không nhất thiết phải xuất hiện trong cùng một câu hoặc đoạn văn. Mô hình này cũng sử dụng cơ chế bộ nhớ để theo dõi các trạng thái sự kiện trong quá trình giải mã, cho phép mô hình duy trì thông tin về các sự kiện và đối số đã trích xuất, từ đó cải thiện độ chính xác khi xử lý các sự kiện liên quan đến nhau, tham khảo chi tiết ở Hình 3.3.

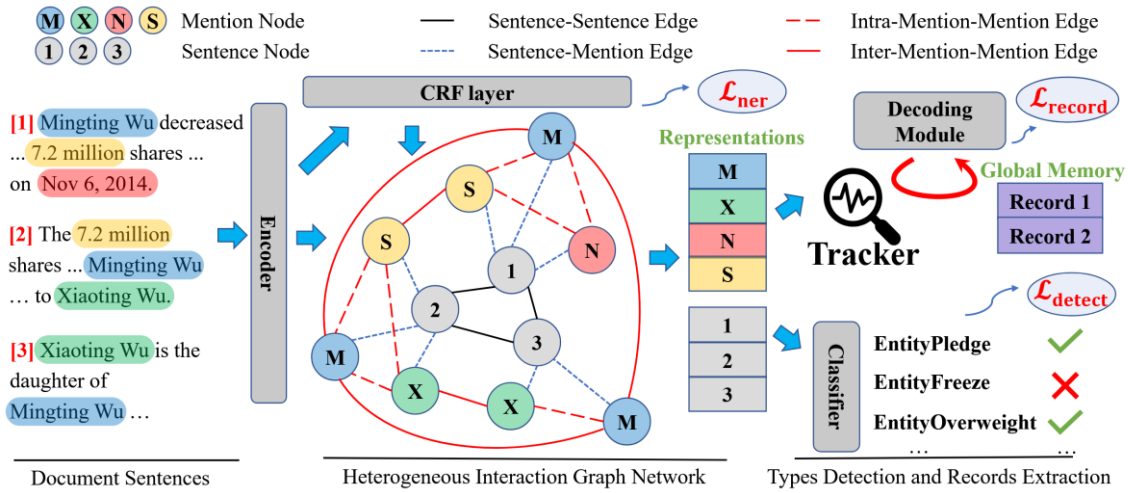

Hình 3.3 Kiến trúc mô hình GIT
(Nguồn: (Xu, Liu, Li, & Chang, 2021))

GIT không chỉ có khả năng mô hình hóa mối quan hệ giữa các sự kiện mà còn có thể cải thiện khả năng xử lý các sự kiện đa sự kiện, nơi nhiều sự kiện xuất hiện trong cùng một văn bản và có mối quan hệ phức tạp với nhau. Tuy nhiên, nhược điểm của phương pháp này là yêu cầu bộ nhớ tính toán lớn và độ phức tạp cao trong việc xử lý các đồ thị dị thể, điều này có thể làm giảm hiệu suất khi áp dụng trên các tập dữ liệu quy mô lớn.

3.5.4 Pseudo-Trigger-aware Pruned Complete Graph (PTPCG)

PTPCG là một mô hình không tự hồi quy, sử dụng đồ thị đầy đủ được tỉa (pruned full graph) để tổ chức và giải mã các sự kiện trong văn bản. Điểm đặc biệt của PTPCG là việc sử dụng pseudo-trigger, những từ hoặc cụm từ có khả năng gợi ý sự xuất hiện của sự kiện mà không nhất thiết phải là từ kích hoạt chính thức, nhằm giảm tải cho mô hình và tối ưu hóa quá trình giải mã. Các pseudo-triggers này được chọn tự động dựa trên mức độ quan trọng của chúng trong ngữ cảnh sự kiện, qua đó giúp mô hình giảm phụ thuộc vào việc xác định từ kích hoạt chính xác và cải thiện khả năng xử lý các sự kiện mà không cần phụ thuộc quá nhiều vào việc nhận diện chính xác trigger words. PTPCG sử dụng đồ thị tỉa để giảm thiểu các cạnh không cần thiết, đồng thời duy trì sự liên kết giữa các đối số và các sự kiện, giúp mô hình tối ưu hóa khả năng tìm kiếm và tổ chức thông tin, chi tiết ở Hình 3.4.

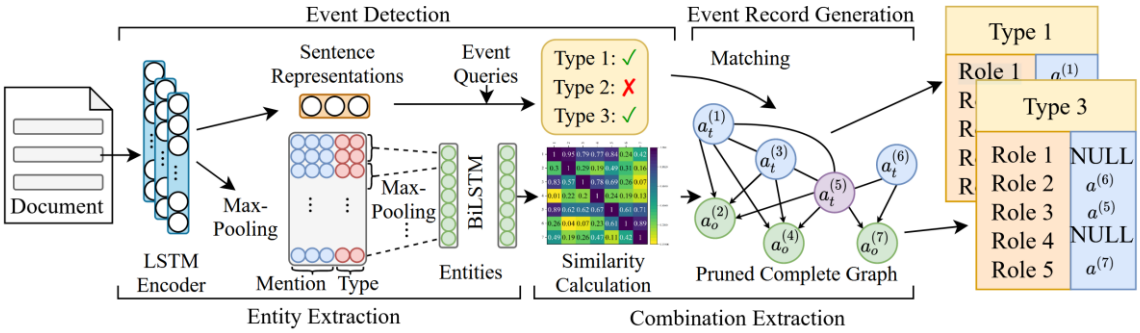

Hình 3.4 Kiến trúc mô hình PTPCG

(Nguồn: (Zhu et al., 2022))

Cơ chế không tự hồi quy giúp PTPCG giảm bớt chi phí tính toán so với các mô hình tự hồi quy truyền thống, đặc biệt khi xử lý văn bản dài và đa sự kiện. Tuy nhiên, việc sử dụng pseudo-triggers cũng có thể dẫn đến một số sai lệch trong các trường hợp, vì những từ này không luôn phản ánh chính xác sự kiện mà chúng gợi ý. Dù vậy, PTPCG vẫn nổi bật trong việc cải thiện tốc độ và hiệu quả tính toán trong các bài toán trích xuất sự kiện phức tạp.

CHƯƠNG 4. QUY TRÌNH XÂY DỰNG TẬP DỮ LIỆU

4.1 Chọn lọc dữ liệu

Dữ liệu là các bản án đã được công bố từ trang thông tin điện tử của Thư Viện Pháp Luật, là một trang chuyên đăng tải các bản tin, văn bản quy phạm pháp luật và các tài liệu pháp lý phục vụ tra cứu. Nội dung sự kiện thường phân bố rải rác trong nhiều phần của bản án, đặc biệt là các đoạn mô tả diễn biến vụ việc và các lập luận thường xuất hiện ở các mục như "Nội dung vụ án" hoặc "Nhận định của Tòa án" của bản án vì đây là nơi nêu chuỗi hành vi, quan hệ giữa các chủ thể, bối cảnh thời gian địa điểm và các tình tiết liên quan. Toàn bộ các đường dẫn đến các bản án liên quan đến lĩnh vực Hình sự được thu thập và thống kê số lượng gồm 202,759 đường dẫn với 131 loại sự kiện khác nhau. Chúng tôi phát hiện trùng lặp đường dẫn, loại bỏ các bản án thiếu mất phần quan trọng hoặc không có nội dung, cuối cùng lọc còn 117,195 đường dẫn hợp lệ. Để đảm bảo phân phối số lượng văn bản của các sự kiện, chỉ các sự kiện có số đường dẫn hợp lệ từ 100 trở lên mới được giữ lại, kết quả thu được 32 loại sự kiện với 113,023 đường dẫn.

4.2 Xây dựng lược đồ dữ liệu sự kiện

Lấy cảm hứng từ các công trình nghiên cứu trước đó (Xian et al., 2024; Yao et al., 2022), lược đồ sự kiện của VLEX được xây dựng theo hướng theo tội, trong đó mỗi loại sự kiện được quy chiếu về các điều kiện cấu thành tội danh theo Bộ luật Hình sự năm 2015 (số 100/2015/QH13) như một nguồn tri thức chuẩn tắc để xác lập phạm vi ngữ nghĩa và ràng buộc thông tin cần thu thập. Cách tiếp cận dựa trên văn bản pháp luật chính thống cho phép lược đồ đạt mức độ chặt chẽ về mặt học thuật, bởi các vai đối số và thuộc tính không được lựa chọn theo trực giác ngôn ngữ mà được dẫn xuất từ những yếu tố có giá trị pháp lý trong quá trình định tội và lượng hình, có thể tham khảo về lược đồ sự kiện chi tiết ở Bảng 4.1. Nhờ đó, lược đồ có khả năng phản ánh các chi tiết mang tính quyết định trong xét xử mà nếu chỉ dựa trên mô tả bề mặt của văn bản bản án có thể bị xem nhẹ hoặc không được hệ thống hóa đầy đủ; chẳng hạn, đối với các tội phạm xâm hại tình dục, một số thuộc tính như độ tuổi

của nạn nhân có thể làm thay đổi đáng kể cách áp dụng điều luật và khung hình phạt, do đó cần được quy định rõ như một thành phần thông tin quan trọng trong cấu trúc sự kiện. Tuy nhiên, việc thiết kế lược đồ bám sát cấu thành tội cũng kéo theo những giới hạn nhất định về độ bao phủ ngữ cảnh và tính thực chứng của dữ liệu. Thứ nhất, lược đồ theo tội có xu hướng tập trung vào các hành vi cấu thành yếu tố phạm tội, trong khi nhiều hành vi diễn ra trước hoặc sau vụ việc, tuy không trực tiếp cấu thành tội, lại có vai trò quan trọng trong lập luận xét xử và đánh giá tình tiết, ví dụ các hành động sau khi xảy ra vụ án như bỏ trốn, tự thú, đầu thú, khắc phục hậu quả hoặc thỏa thuận bồi thường. Các hành vi này thường xuất hiện trong bản án như các tình tiết ảnh hưởng đến nhận định của tòa và quyết định cuối cùng, vì vậy nếu lược đồ chỉ giới hạn trong khung cấu thành tội sẽ khó mô tả đầy đủ dòng diễn biến của vụ việc ở cấp độ văn bản. Thứ hai, phạm vi các tội danh và các biến thể cấu thành trong văn bản pháp luật là rất rộng, dẫn đến khả năng xuất hiện những loại sự kiện có tần suất thấp hoặc mang tính đặc thù cao trong dữ liệu thực tế; nếu đưa toàn bộ vào lược đồ sẽ làm tăng đáng kể kích thước và độ phân mảnh của tập nhãn, kéo theo tình trạng mất cân bằng dữ liệu giữa các loại sự kiện và làm suy giảm tính đồng đều về chất lượng chú giải do số lượng mẫu cho từng loại không đủ để đại diện. Trên cơ sở cân nhắc giữa tính chuẩn tắc của nền tảng pháp lý và yêu cầu thực nghiệm của một tập dữ liệu trích xuất sự kiện, VLEX vì vậy được xây dựng theo hướng lựa chọn những loại sự kiện phổ biến và có tần suất xuất hiện đủ lớn trong bản án, đồng thời thiết kế lược đồ theo nguyên tắc bảo đảm đầy đủ các đối số tham gia để mô tả trọn vẹn sự kiện theo yêu cầu pháp lý, nhưng không giới hạn ở các yếu tố cấu thành tội mà còn mở rộng để bao quát các chi tiết ngữ cảnh thường xuyên được viện dẫn trong lập luận xét xử, thông tin các đối số của từng loại sự kiện được mô tả cụ thể ở Bảng 4.1. Cách thiết kế này giúp lược đồ vừa duy trì tính chuyên biệt và chặt chẽ của miền pháp lý, vừa phản ánh đặc trưng diễn ngôn của bản án và đáp ứng tốt hơn mục tiêu trích xuất sự kiện ở cấp độ văn bản, nơi một sự kiện thường chỉ có thể được tái dựng đầy đủ khi kết hợp thông tin từ nhiều đoạn khác nhau trong tài liệu.

Bảng 4.1 Lược đồ sự kiện của tập dữ liệu VLEX

Nhóm sự kiện	Loại sự kiện	Đối số
Xâm phạm tính mạng, sức khỏe, nhân phẩm, danh dự của con người	giết người	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, công cụ gây án, hành động tấn công, vùng thương tổn, mức độ thương tổn, lí do, nguyên nhân cái chết (11 đối số)
	gây thương tích	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, hành động tấn công, công cụ gây án, vùng thương tổn, mức độ thương tổn (9 đối số)
	hiếp dâm	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, vùng thương tổn, mức độ thương tổn, tuổi nạn nhân (8 đối số)
	giao cấu	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, vùng thương tổn, mức độ thương tổn, tuổi nạn nhân (8 đối số)
	dâm ô	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, vùng thương tổn, mức độ thương tổn, tuổi nạn nhân (8 đối số)
Xâm phạm sở hữu	cướp tài sản	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, công cụ

		gây án, phương tiện gây án, tài sản, giá trị tài sản (9 đối số)
	cưỡng đoạt tài sản	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, nội dung đe dọa, công cụ gây án, tài sản, giá trị tài sản, tài sản chưa sử dụng, số giá trị tài sản chưa sử dụng (11 đối số)
	cướp giật tài sản	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, công cụ gây án, phương tiện gây án, tài sản, giá trị tài sản, tài sản chưa sử dụng, giá trị tài sản chưa sử dụng (11 đối số)
	trộm cắp tài sản	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, công cụ gây án, phương tiện gây án, tài sản, giá trị tài sản, tài sản chưa sử dụng, giá trị tài sản chưa sử dụng (11 đối số)
	lừa đảo chiếm đoạt tài sản	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, nội dung lừa đảo, công cụ gây án, phương tiện gây án, tài sản, giá trị tài sản, tài sản chưa sử dụng, giá trị tài sản chưa sử dụng (11 đối số)
	lạm dụng tín nhiệm chiếm đoạt tài sản	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, chức vụ, công cụ gây án, tài sản, giá trị tài

		sản, tài sản chưa sử dụng, giá trị tài sản chưa sử dụng (11 đối số)
Phạm tội về ma túy	tàng trữ trái phép chất ma túy	thời gian, địa điểm, bị cáo, hành vi sau vụ việc, loại chất ma túy, khối lượng ma túy (6 đối số)
	vận chuyển trái phép chất ma túy	thời gian, địa điểm khởi hành, địa điểm mục tiêu, bị cáo, hành vi sau vụ việc, phương tiện gây án, loại chất ma túy, khối lượng ma túy (8 đối số)
	mua bán trái phép chất ma túy	thời gian, địa điểm, người bán, người mua, hành vi sau vụ việc, loại chất ma túy, khối lượng ma túy (7 đối số)
	tổ chức sử dụng trái phép chất ma túy	thời gian, địa điểm, bị cáo, hành vi sau vụ việc, hình thức, loại chất ma túy, khối lượng ma túy (7 đối số)
Xâm phạm an toàn, trật tự công cộng	vi phạm quy định về tham gia giao thông đường bộ	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, công cụ gây án, phương tiện gây án, vùng thương tổn, mức độ thương tổn, lí do (10 đối số)
	gây rối trật tự công cộng	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, công cụ gây án, hành động tấn công, vùng thương tổn, mức độ thương tổn (9 đố số)
	đánh bạc	thời gian, địa điểm, người tham gia, hành vi sau vụ việc, công cụ gây án,

		hình thức, tài sản trao đổi, giá trị tài sản (8 đối số)
	tổ chức đánh bạc hoặc gá bạc	thời gian, địa điểm, người tham gia, hành vi sau vụ việc, công cụ gây án, hình thức, tài sản trao đổi, giá trị tài sản (8 đối số)
	chứa mại dâm	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, hình thức, tài sản trao đổi, giá trị tài sản trao đổi (8 đối số)
	môi giới mại dâm	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, hình thức, tài sản trao đổi, giá trị tài sản trao đổi (8 đối số)
Phạm tội về chức vụ	tham ô tài sản	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, công cụ gây án, giá trị tài sản, tài sản (8 đối số)
	thiếu trách nhiệm	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, công cụ gây án, hành vi thiếu trách nhiệm, thiệt hại (8 đối số)
Khác	chống người thi hành công vụ	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, công cụ gây án, hành động tấn công (7 đối số)
	cho vay lãi nặng	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, hình thức, tài sản, giá trị tài sản (8 đối số)

	vi phạm quy định bảo vệ động vật nguy cấp, quý, hiếm	thời gian, địa điểm, bị cáo, nạn nhân, hành vi sau vụ việc, công cụ gây án, hành động tấn công, vùng thương tổn, mức độ thương tổn, lí do, nguyên nhân cái chết (11 đối số)

4.3 Trích lọc dữ liệu

4.3.1 Trích lọc văn bản

Các bản án trong tập dữ liệu được thu thập từ các đường dẫn hợp lệ và có thể truy vết, sau đó được chuẩn hóa theo hướng chỉ giữ lại những phần mang thông tin tường thuật và lập luận phục vụ trực tiếp cho việc khôi phục diễn biến sự việc, cụ thể là mục "Nội dung bản án" và "Nhận định của tòa án". Từ các phần này, văn bản được trích xuất các đoạn mô tả tiến trình vụ việc theo trình tự, bao gồm các hành vi và tương tác giữa các chủ thể liên quan, bối cảnh xảy ra sự việc, cùng các tác động và thiệt hại mà nạn nhân phải gánh chịu, nhằm bảo toàn các chi tiết cần thiết cho việc nhận diện sự kiện ở cấp độ văn bản. Để hạn chế nhiễu do văn bản quá dài dẫn đến dàn trải thông tin và đồng thời tránh việc các văn bản quá ngắn làm sự kiện bị phân mảnh thành các mẩu thông tin rời rạc hoặc quá chi li, dữ liệu được lọc theo độ dài, chỉ giữ lại những văn bản có số từ từ 50 đến dưới 1,750 từ. Sau bước chuẩn hóa và lọc theo tiêu chí độ dài, tập dữ liệu thu được gồm 7,614 văn bản có chất lượng tương đối đồng đều và giàu thông tin, bao phủ 6 nhóm sự kiện với 29 loại sự kiện, qua đó phản ánh cả mức độ đa dạng về thể loại lẫn quy mô về số lượng, tạo tiền đề thuận lợi cho các nghiên cứu và thực nghiệm tiếp theo trên bài toán trích xuất sự kiện ở cấp độ văn bản.

4.3.2 Trích lọc từ kích hoạt sự kiện

Đối với mỗi loại sự kiện, nhằm bảo đảm ý nghĩa thống kê tối thiểu và giảm thiên lệch do lựa chọn chủ quan, chúng tôi tiến hành chọn ngẫu nhiên 30 văn bản đại diện để xây dựng tập mẫu phục vụ trích lọc từ kích hoạt sự kiện. Trên tập mẫu này,

các biểu thức ngôn ngữ có chức năng kích hoạt sự kiện được rà soát và tổng hợp theo nguyên tắc ưu tiên những từ hoặc cụm từ có khả năng gợi mở rõ ràng sự kiện mục tiêu trong ngữ cảnh pháp lý, đồng thời xuất hiện ổn định qua nhiều văn bản và có tính phân biệt tương đối so với các sự kiện khác. Quy trình này giúp cung cấp một cơ sở tham chiếu nhất quán cho người gán nhãn khi xác định ngữ nghĩa của sự kiện trong văn bản, qua đó giảm mức độ mơ hồ và hạn chế sai sót trong cách hiểu giữa các cá nhân. Song song với việc đề xuất các ứng viên từ kích hoạt, chúng tôi cũng thực hiện bước sàng lọc nhằm loại trừ những biểu thức quá chung, phụ thuộc mạnh vào ngữ cảnh, hoặc không phản ánh đặc trưng cốt lõi của sự kiện, vì các trường hợp này dễ dẫn đến nhận diện nhầm hoặc làm suy giảm độ nhất quán trong quá trình gán nhãn.

Kết quả của giai đoạn trích lọc và chuẩn hóa này là một danh sách gồm 64 từ hoặc cụm từ kích hoạt tiêu chuẩn, được sử dụng như tài nguyên nền để định hướng người gán nhãn trong việc phát hiện từ kích hoạt, đồng thời đóng vai trò làm chuẩn tham chiếu khi xem xét các trường hợp ngoại lệ hoặc các biến thể diễn đạt trong dữ liệu.

4.3.3 Trích xuất sự kiện

Toàn bộ quá trình xây dựng nhãn cho tập dữ liệu được triển khai trên nền tảng web INCEpTION[2] (Klie, Bugert, Boullosa, Eckart de Castilho, & Gurevych, 2018), một môi trường hỗ trợ gán nhãn được sử dụng rộng rãi trong các tác vụ trích xuất thông tin, trong đó có trích xuất sự kiện, nhờ khả năng tổ chức dự án, quản lý lược đồ nhãn và theo dõi tiến độ chú giải theo từng tài liệu một cách tập trung. Việc lựa chọn INCEpTION nhằm bảo đảm rằng dữ liệu được tạo lập theo một quy trình nhất quán, có thể kiểm soát và truy vết, đồng thời giảm thiểu các sai lệch phát sinh do thao tác thủ công rời rạc hoặc do sử dụng nhiều công cụ khác nhau trong các giai đoạn khác nhau. Trên nền tảng này, dự án gán nhãn được cấu hình để phục vụ trực tiếp cho yêu cầu của bài toán trích xuất sự kiện, nghĩa là các lớp nhãn và quy tắc thao tác được

[2] https://github.com/inception-project/inception

thiết lập thống nhất cho toàn bộ nhóm gán nhãn, giúp các quyết định chú giải được thực hiện trong cùng một khuôn khổ biểu diễn, ví dụ về cách một văn bản được gán nhãn có thể xem ở Hình 4.1. Từ góc độ vận hành, việc gán nhãn được tổ chức theo hướng mỗi văn bản được xử lý như một đơn vị độc lập trong kho dữ liệu, và mọi thao tác chú giải đều được ghi nhận trong hệ thống, qua đó hỗ trợ việc kiểm tra chất lượng và đối chiếu khi cần đánh giá lại các trường hợp gây tranh cãi hoặc có mức độ mơ hồ cao trong diễn giải.

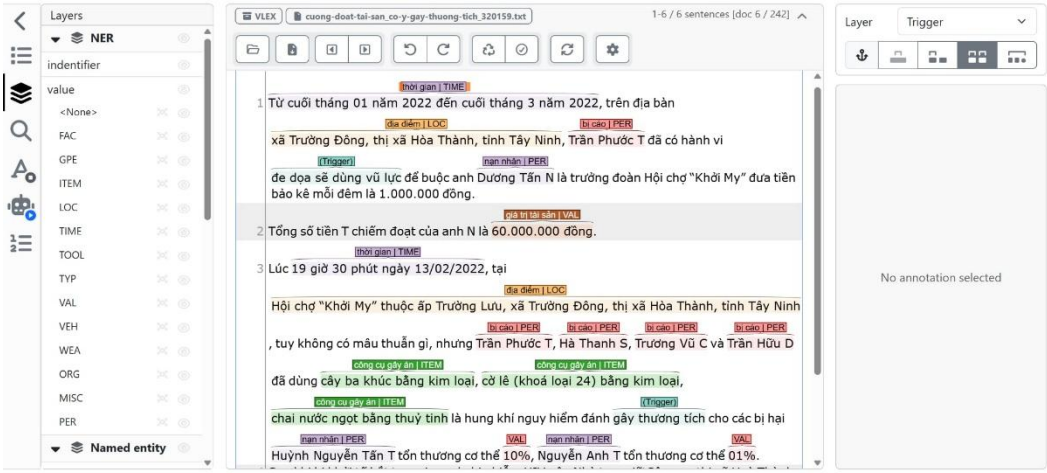

Hình 4.1 Giao diện trang gán nhãn trong hệ thống đánh nhãn INCEpTION

Các sự kiện trong dữ liệu được chú giải bởi ba người gán nhãn, trong đó có hai người gán nhãn là sinh viên ngành Luật, có nền tảng kiến thức chuyên môn về cấu trúc văn bản pháp lý và hiểu biết về các hành vi phạm tội được mô tả trong bản án hình sự. Điều này giúp giảm thiểu sai lệch do thiếu kiến thức chuyên gia, vốn thường là nguyên nhân phổ biến dẫn tới tính không đồng nhất khi xử lý các mô tả pháp lý mang tính quy chuẩn, nhiều thuật ngữ chuyên ngành và có đặc trưng lập luận chặt chẽ. Để bảo đảm tính khách quan và minh bạch của dữ liệu, mỗi văn bản được gán nhãn độc lập bởi từng người gán nhãn, tức là trong giai đoạn chú giải chính thức, mỗi người đưa ra quyết định dựa trên cùng một bộ hướng dẫn và cùng một lược đồ nhãn nhưng không bị tác động bởi lựa chọn của người khác, nhờ đó mức độ đồng thuận đo được phản ánh thực chất chất lượng hướng dẫn và khả năng áp dụng của

người gán nhãn trong điều kiện làm việc độc lập. Cách tổ chức này cũng giúp nhận diện sớm các điểm chưa rõ trong hướng dẫn hoặc các trường hợp nhập nhằng trong ngữ nghĩa văn bản, bởi những điểm đó thường biểu hiện trực tiếp qua sự suy giảm mức độ đồng thuận giữa các cá nhân.

Trên cơ sở của các công trình nghiên cứu gần đây về trích xuất sự kiện ở cấp độ văn bản (Han et al., 2022a; Tong et al., 2022; Yao et al., 2022), chúng tôi sử dụng Cohen's kappa như chỉ số đánh giá độ đồng thuận giữa các người gán nhãn, thường được gọi là IAA (Inter-Annotator Agreement), nhằm định lượng mức nhất quán của nhãn. Việc sử dụng Cohen's kappa trong bối cảnh này có ý nghĩa như một cơ chế kiểm soát chất lượng mang tính định lượng, cho phép theo dõi tiến trình ổn định của quá trình gán nhãn theo thời gian, thay vì chỉ đánh giá một lần ở cuối dự án, đồng thời cung cấp căn cứ rõ ràng để ra quyết định can thiệp khi chất lượng chưa đạt yêu cầu. Cụ thể, tập văn bản được chia ngẫu nhiên thành mười phần có kích thước xấp xỉ tương đương để triển khai theo từng đợt gán nhãn. Cách chia theo đợt được lựa chọn nhằm tạo ra các chu kỳ kiểm tra đều đặn, trong đó sau mỗi chu kỳ, mức độ đồng thuận được tính toán lại để đánh giá xem nhóm gán nhãn có đang có quan điểm đồng thuận và cách áp dụng hướng dẫn hay không. Sau khi hoàn thành gán nhãn cho từng phần, chúng tôi tính kappa trung bình giữa các người gán nhãn để hạn chế việc đánh giá dựa trên một cặp người gán nhãn riêng lẻ có thể không đại diện hết cho toàn bộ nhóm. Quy trình được thiết kế theo nguyên tắc chỉ cho phép chuyển sang giai đoạn tiếp theo khi kappa trung bình đạt ngưỡng tối thiểu 70%, coi đây là mức đồng thuận đủ để tiếp tục mở rộng quy mô mà không làm tích lũy sai lệch hệ thống trong dữ liệu. Trong trường hợp kappa trung bình thấp hơn 70%, nhóm gán nhãn sẽ quay lại thực hiện gán nhãn lại phần văn bản trước đó vừa hoàn thành, nhằm kịp thời khắc phục các bất đồng nhất trước khi chúng lan sang các phần dữ liệu tiếp theo. Cơ chế chặn theo ngưỡng này đóng vai trò như một vòng phản hồi chất lượng, giúp dự án gán nhãn duy trì được tiêu chuẩn ổn định trong suốt quá trình triển khai, đồng thời tạo ra động lực chuẩn hóa cách hiểu của người gán nhãn đối với các trường hợp khó, các biểu thức biên và những ngữ cảnh dễ gây nhầm lẫn.

Trên phương diện thực hành, việc phải gán nhãn lại không chỉ mang ý nghĩa sửa lỗi ở cấp văn bản cụ thể, mà quan trọng hơn là tạo cơ hội để người gán nhãn nhận diện các điểm cần thống nhất trong cách diễn giải và áp dụng, từ đó làm giảm biến thiên do yếu tố chủ quan và nâng cao độ tin cậy của dữ liệu ở cấp toàn tập. Kết thúc toàn bộ quy trình, chúng tôi thu được tập dữ liệu VLEX được gán nhãn thủ công với chất lượng cao, thể hiện qua mức IAA đạt 81,3%, cho thấy mức độ đồng thuận giữa các người gán nhãn là tốt và đủ tin cậy để sử dụng làm cơ sở cho các thực nghiệm và phân tích tiếp theo trong bài toán trích xuất sự kiện ở cấp độ văn bản.

CHƯƠNG 5. PHÂN TÍCH THỐNG KÊ DỮ LIỆU

5.1 Kích thước dữ liệu

Tập dữ liệu VLEX bao gồm tổng cộng 7,614 văn bản đã được gán nhãn và trải qua quy trình đánh giá chất lượng, trong đó ghi nhận 11,042 sự kiện thuộc 29 loại sự kiện, được tổ chức thành 6 nhóm sự kiện theo định hướng lược đồ đã xây dựng. Ở cấp độ đối số, tập dữ liệu chứa 51,697 đối số tham gia sự kiện, tương ứng với 48 vai trò đối số được định nghĩa, phản ánh mức độ đa dạng trong cấu trúc biểu diễn sự kiện. Xét ở cấp câu, toàn bộ tập dữ liệu gồm 55,068 câu, từ đó suy ra độ dài trung bình của một văn bản xấp xỉ 7.23 câu, cho thấy dữ liệu duy trì độ dài vừa phải để nắm bắt bối cảnh và diễn tiến vụ việc.

Khi phân tích theo từng loại sự kiện, có thể quan sát thấy sự khác biệt đáng kể về độ dài và mức độ chi tiết của văn bản giữa các nhóm, phản ánh đặc trưng diễn ngôn và mức độ phức hợp của từng loại vụ việc trong bản án hình sự. Cụ thể, loại sự kiện *mua bán trái phép chất ma túy* có số câu trung bình trên một văn bản cao nhất, đạt 9.32 câu, gợi ý rằng các văn bản thuộc loại này thường chứa có nhiều sự kiện, có diễn biến phức tạp dẫn đến cấu trúc tường thuật kéo dài hơn so với các loại sự kiện khác. Ở khía cạnh khác, xét theo độ dài tuyệt đối của văn bản, sự kiện *cướp tài sản* ghi nhận trường hợp văn bản dài nhất với 1,735 từ, khi vụ việc có nhiều tình tiết và nhiều bị cáo, bị hại và mốc thời gian liên quan.

Bên cạnh các thống kê mô tả nội tại, chúng tôi cũng tiến hành đối chiếu các đặc trưng cơ bản của VLEX với một số tập dữ liệu tiêu biểu khác, bao gồm các tập dữ liệu pháp lý, các tập dữ liệu trích xuất sự kiện tổng quát, cũng như các tập dữ liệu trích xuất sự kiện thuộc miền dữ liệu tiếng Việt, nhằm làm rõ vị trí tương đối của VLEX về quy mô, mức độ đa dạng loại sự kiện và độ phong phú vai trò đối số, phần so sánh chi tiết được trình bày tại Bảng 5.1 và Bảng 5.2.

Bảng 5.1 Bảng so sánh thông tin của VLEX và một số tập dữ liệu khác trong lĩnh vực pháp lý

Tập dữ liệu	**VLEX**	**DLEE**	**LEVEN**	**CLEE**	**DivorceEE**
Lĩnh vực	Pháp lý	Pháp lý	Pháp lý	Pháp lý	Pháp lý
Cấp độ trích xuất	Văn bản	Văn bản	Câu	Câu	Câu
Ngôn ngữ	Tiếng Việt	Tiếng Trung	Tiếng Trung	Tiếng Trung	Tiếng Trung
Số lượng văn bản	7614	10014	8116	_	_
Số lượng câu	55068	_	63616	6538	3100
Số loại sự kiện	29	49	108	5	13
Số vai trò đối số	48	378	_	20	40
Số sự kiện	11042	10014	150977	6538	3100
Số đối số	51697	~100000	_	_	_
Tỉ lệ văn bản có đa sự kiện	19.5%	0%	_	0%	0%

Bảng 5.2 Bảng so sánh thông tin của VLEX và các tập dữ liệu trong một số lĩnh vực nổi bật

Tập dữ liệu	**VLEX**	**BKEE**	**VHE**	**DuEE-fin**	**ChFinAnn**
Lĩnh vực	Pháp lý	Tổng quát	Lịch sử	Tài chính	Tài chính
Cấp độ trích xuất	Văn bản	Câu	Câu	Văn bản	Văn bản
Ngôn ngữ	Tiếng Việt	Tiếng Việt	Tiếng Việt	Tiếng Trung	Tiếng Trung
Số lượng văn bản	7,614	1,066	_	11645	32040
Số lượng câu	55,068	21,318	4,114	_	_
Số loại sự kiện	29	33	35	13	5
Số vai trò đối số	48	28	11	92	35
Số sự kiện	11,042	_	5,237	15850	47284
Số đối số	51,697	_	13,362	81632	289871
Tỉ lệ văn bản có đa sự kiện	19.5%	_	_	29.2%	29%

5.2 Phân phối dữ liệu

Phân bố số lượng văn bản theo nhóm sự kiện cho thấy dữ liệu tập trung chủ yếu ở hai nhóm *Xâm phạm sở hữu* và *Phạm tội về ma túy*, với tỷ lệ lần lượt đạt 27,6% và 38,7%, thể hiện ở Bảng 5.3, phản ánh mức độ phổ biến và tần suất xuất hiện cao của các nhóm tội danh này trong nguồn bản án được thu thập.

Bảng 5.3 Tỉ lệ văn bản có gãn nhãn bởi sáu nhóm sự kiện của VLEX

Nhóm sự kiện	**Tỉ lệ**
Xâm phạm tính mạng, sức khỏe, nhân phẩm, danh dự của con người	14.4%
Xâm phạm sở hữu	25.7%
Phạm tội về ma tuý	37.4%
Xâm phạm an toàn, trật tự công cộng	14.6%
Phạm tội về chức vụ	3.2%
Khác	4.7%

Sự tập trung này thể hiện rõ khi xét theo mức độ chiếm lĩnh ở các loại sự kiện, cụ thể có tám trong mười loại sự kiện sở hữu số văn bản lớn nhất thuộc về hai nhóm nói trên, xem chi tiết tại Hình 5.1.

Ngoài ra, VLEX được khai thác theo thiết lập đa sự kiện ở cấp độ văn bản, nghĩa là một tài liệu không bị giả định chỉ chứa một sự kiện chính mà có thể bao gồm nhiều sự kiện khác nhau cùng xuất hiện, bổ trợ thông tin và tạo thành các mối liên hệ trong dòng diễn biến vụ án.

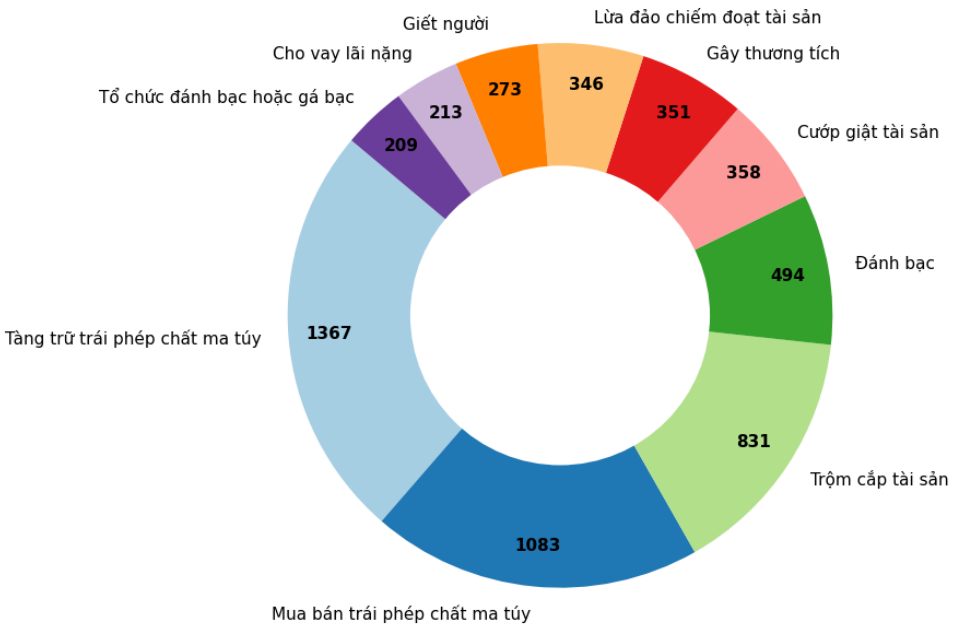

Hình 5.1 Biểu đồ tròn khuyết thể hiện số lượng văn bản của top 10 loại sự kiện có số lượng văn bản nhiều nhất

Thống kê cho thấy 19,5% văn bản trong VLEX thuộc nhóm đa sự kiện, được mô tả ở Bảng 5.1, tức trong cùng một văn bản có từ hai sự kiện trở lên, qua đó phản ánh một kịch bản gần với thực tế của bản án hình sự, nơi hành vi phạm tội chính thường đi kèm các hành vi liên quan, tình tiết phát sinh hoặc các sự kiện phụ trợ có ý nghĩa trong lập luận xét xử. Tỷ lệ này cho thấy VLEX không chỉ phù hợp cho thiết lập trích xuất sự kiện đơn lẻ mà còn đủ độ phức tạp để đánh giá năng lực của các mô hình trong bài toán trích xuất đa sự kiện, đặc biệt trong các trường hợp cần tách biệt đúng biên giữa các sự kiện đồng thời, liên kết đúng đối số theo từng sự kiện và xử lý sự phân tán thông tin trên toàn văn bản.

CHƯƠNG 6. THỰC NGHIỆM

6.1 Mô hình cơ sở và phương pháp đánh giá

Để đánh giá tập dữ liệu, các mô hình cơ sở được triển khai và tiến hành chạy thực nghiệm so sánh bao gồm:

- **DCFEE-O** và **DCFEE-M** (Yang et al., 2018): mô hình trích xuất sự kiện cấp độ văn bản khai thác cơ chế gán nhãn từ xa và các bước hợp nhất thông tin liên câu để tạo bản ghi sự kiện.
- **Doc2EDAG** (Zheng et al., 2019): mô hình đầu cuối theo hướng điền bảng, biểu diễn mỗi sự kiện như một bản ghi và giải mã bằng cấu trúc EDAG để tạo nhiều bản ghi sự kiện trong cùng văn bản.
- **GIT** (Xu et al., 2021): mô hình hóa tương tác toàn cục trong văn bản bằng đồ thị dị thể và cơ chế theo dõi bản ghi để nắm bắt phụ thuộc giữa các sự kiện và đối số.
- **PTPCG** (Zhu et al., 2022): phương pháp không tự hồi quy dựa trên đồ thị đầy đủ được tỉa và pseudo-trigger để khôi phục tổ hợp đối số và sinh bản ghi sự kiện hiệu quả.

Cũng như các công trình nghiên cứu ở trên, với mỗi bản ghi dự đoán trong một văn bản, tìm bản ghi chuẩn tương tự nhất để nhận được điểm trùng khớp; hai bản ghi được xem là khớp khi cùng loại sự kiện, và mức độ khớp được quyết định bởi số lượng đối số khớp chính xác, từ đó đếm tổng số đối số khớp để suy ra Precision, Recall và F1 cho toàn bộ hệ thống.

6.2 Cài đặt thực nghiệm

Tập dữ liệu được phân chia thành ba phần gồm tập huấn luyện, tập phát triển và tập kiểm thử theo tỷ lệ 8:1:1 nhằm phục vụ cho quá trình xây dựng mô hình, lựa chọn siêu tham số và đánh giá cuối cùng một cách khách quan. Quá trình chia tách được thực hiện theo hướng kiểm soát phân bố nhãn, trong đó mỗi tập con đều bao gồm đầy đủ các loại sự kiện xuất hiện trong toàn bộ tập dữ liệu, qua đó hạn chế nguy cơ một số loại sự kiện bị thiếu hoặc quá ít ở tập phát triển hay tập kiểm thử, vốn có

thể gây sai lệch trong đánh giá hiệu năng và làm giảm ý nghĩa so sánh giữa các mô hình. Đồng thời, việc duy trì sự tương đồng tương đối về tỷ lệ các loại sự kiện giữa các tập giúp kết quả thực nghiệm phản ánh đúng năng lực tổng quát hóa của mô hình thay vì bị chi phối bởi mất cân bằng phân bố nhãn do chia tách ngẫu nhiên, đặc biệt trong bối cảnh dữ liệu đa sự kiện nơi một văn bản có thể chứa nhiều sự kiện thuộc các loại khác nhau, thông tin chi tiết xem ở Bảng 6.1.

Bảng 6.1 Thống kê về số liệu các tập dữ liệu được chia thành để thực nghiệm

	Tập huấn luyện	**Tập kiểm thử**	**Tập kiểm tra**	**Tổng cộng**
Số lượng văn bản	6092	761	761	7614
Số lượng sự kiện	8760	1044	1238	11042

Các thí nghiệm được tiến hành chạy trên 02 RTX 3090 24GB với 100 epoch, sử dụng mô hình embedding bert-base-multilingual-cased (Devlin, Chang, Lee, & Toutanova, 2019) với khoảng 110,000,000 tham số và đặc biệt có hỗ trợ ngôn ngữ tiếng Việt, các thông số cài đặt còn lại đều giữ nguyên dựa trên các nghiên cứu trước đó (Yang et al., 2018; Zhu et al., 2022).

6.3 Kết quả thực nghiệm

Bảng 6.2 Kết quả thực nghiệm của các mô hình cơ sở trên tập dữ liệu VLEX

Mô hình	**Precision**	**Recall**	**F1**
DCFEE-O	53,5	48,7	52,6
DCFEE-M	41,4	39,8	43
Doc2EDAG	59,6	52,4	57,7
GIT	60,4	53,1	59,3
PTPCG	63,2	57,9	61,5

Nhìn tổng thể, kết quả thực nghiệm cho thấy một xu hướng nhất quán: các mô hình được thiết kế cho trích xuất sự kiện ở cấp độ văn bản và có cơ chế tổ chức cấu trúc sự kiện rõ ràng đạt hiệu năng cao hơn đáng kể, qua đó phản ánh đúng mức độ phù hợp giữa giả định mô hình hóa và đặc trưng dữ liệu pháp lý của VLEX. Trường hợp đáng chú ý nhất là khoảng cách lớn giữa hai biến thể DCFEE, trong đó DCFEE-O đạt mức F1 trung bình, còn DCFEE-M suy giảm mạnh. Trong bối cảnh VLEX, thông tin về cùng một sự kiện thường được phân bố ở nhiều đoạn khác nhau, đôi khi bị dừng lại bởi phần nhận định, viện dẫn hoặc mô tả tình tiết tăng nặng giảm nhẹ; vì vậy, nếu cơ chế chọn câu then chốt hoặc cơ chế gom đối số của quy trình không đủ ổn định, lỗi sẽ lan truyền theo dây chuyền từ bước nhận diện sang bước ghép vai và cuối cùng làm giảm mạnh khả năng thu hồi đối số, dẫn đến hiện tượng Recall tụt sâu và kéo theo F1 giảm. Nói cách khác, DCFEE thể hiện rõ hạn chế mang tính cấu trúc của quy trình trong môi trường cấp vâ nản: một khi các quyết định trung gian sai, mô hình rất khó "tự sửa" ở các bước sau, đặc biệt khi phải đồng thời phân biệt nhiều sự kiện cùng tồn tại trong một văn bản.

Ngược lại, nhóm mô hình Doc2EDAG, GIT và PTPCG thể hiện mức cải thiện có hệ thống, trong đó điểm đáng nhấn mạnh không nằm ở từng con số cụ thể mà ở sự chuyển dịch về cơ chế suy luận. Doc2EDAG đạt bước nhảy đáng kể so với DCFEE, điều này phù hợp với lập luận rằng khi bài toán được đặt đúng dưới dạng điền bảng sự kiện thay vì trích xuất rời rạc, mô hình có xu hướng tạo ra các cấu hình vai–đối số hợp lệ hơn và giảm dự đoán nhiễu, tức Precision được cải thiện rõ rệt. Tuy vậy, khoảng cách giữa Precision và Recall vẫn còn tương đối đáng kể, gợi ý rằng dù Doc2EDAG mô hình hóa tốt cấu trúc record, nó vẫn gặp thách thức trong việc thu hồi đầy đủ các đối số khi chúng nằm xa nhau hoặc khi một văn bản chứa nhiều bản ghi có quan hệ chồng lấn về thực thể. Đây là điểm khó điển hình của trích xuất đa sự kiện: cùng một thực thể có thể tham gia nhiều sự kiện hoặc được nhắc lại dưới các dạng đồng tham chiếu khác nhau, đòi hỏi mô hình phải nắm bắt tốt ngữ cảnh toàn cục hơn là chỉ dựa vào quyết định theo từng bước giải mã.

Điểm đáng chú ý là GIT hiệu quả hơn Doc2EDAG một cách ổn định, và sự nhỉnh này có thể được diễn giải như lợi thế của các cơ chế mô hình hóa tương tác toàn cục và theo dõi trạng thái bản ghi trong quá trình suy luận. Trong văn bản pháp lý, không chỉ có sự phân tán thông tin, mà còn có tính phụ thuộc liên đoạn rất cao, ví dụ một tình tiết được giới thiệu ở phần nội dung vụ án nhưng ý nghĩa pháp lý của nó lại được khẳng định hoặc phủ định ở phần nhận định. Vì vậy, việc GIT cải thiện đồng thời cả khả năng chính xác lẫn khả năng thu hồi có thể được hiểu là mô hình đã giảm bớt hai lỗi phổ biến trong đa sự kiện: nhầm phân bổ đối số giữa các sự kiện khác nhau và bỏ sót đối số nằm ở các đoạn không gần điểm neo. Cuối cùng, trường hợp nổi bật nhất về hiệu năng là PTPCG đạt kết quả cao nhất và đặc biệt thể hiện ưu thế ở khả năng thu hồi, tức Recall cao hơn các mô hình còn lại một cách đáng kể trong khi Precision vẫn được duy trì ở mức tốt. Đây là dấu hiệu quan trọng vì trong đánh giá theo bản ghi sự kiện, sai sót thường bị phạt khi thiếu đối số hoặc thiếu một bản ghi, do đó việc cải thiện Recall thường khó hơn cải thiện Precision. Một cách lý giải hợp lý là cơ chế tổ chức suy luận của PTPCG theo đồ thị và việc sử dụng pseudo-trigger như một tín hiệu điều phối đã giúp mô hình khai thác quan hệ giữa các ứng viên đối số hiệu quả hơn trong văn bản dài, đồng thời tránh được hiện tượng tích lũy sai số của giải mã tuần tự.

6.4 Phân tích lỗi

Để khảo sát các thách thức mà VLEX đặt ra, chúng tôi đã lựa chọn ngẫu nhiên 100 trường hợp lỗi trong quá trình chạy thí nghiệm với mô hình PTPCG và tiến hành tổng hợp kết quả để phân tích. Qua đó, chúng tôi xác định được một số lỗi phổ biến mà các mô hình gặp phải trong việc trích xuất sự kiện từ văn bản pháp lý tiếng Việt. Các lỗi này có thể được phân loại thành những nhóm chính sau:

Lỗi xác định sai vùng văn bản (38%): Đây là lỗi khá phổ biến trong các tác vụ trích xuất sự kiện, đặc biệt khi các thực thể hoặc thuộc tính liên quan đến sự kiện không được nhận diện đầy đủ hoặc chính xác. Ví dụ, trong một sự kiện cướp tài sản, cụm từ chỉ tài sản bị cướp có thể là “YAMAHA Sirius BKS 73F1-487.96”, nhưng mô hình chỉ nhận diện được phần “YAMAHA”. Lỗi này thường xuất phát từ việc

tokenization hoặc embedding của mô hình bị lỗi, khiến cho các mô hình không thể nhận diện đúng các từ ngữ phức tạp hoặc các ký tự đặc biệt trong cụm từ. Tokenization không chính xác có thể dẫn đến việc các thành phần quan trọng của văn bản bị bỏ sót hoặc nhận diện sai, ảnh hưởng nghiêm trọng đến việc phân loại và trích xuất sự kiện.

Lỗi đồng tham chiếu đối số (17%): Lỗi này xuất hiện khi một sự kiện có nhiều diễn biến, với các đối số như địa điểm, thời gian hoặc công cụ được đề cập nhiều lần trong văn bản. Ban đầu, những đối số này có thể được mô tả rõ ràng với một địa điểm cụ thể, thời gian, hay thực thể như "Khoảng 17h ngày 25/9/2024", "nhà Nguyễn Phúc A tại thôn M, xã H, thị xã Hương Trà, tỉnh Thừa Thiên Huế", hay "dao thái lan vàng dài 20cm". Tuy nhiên, sau đó, khi các tình tiết sự kiện phát triển, những đối số này có thể được mô tả theo dạng đồng tham chiếu như "Khoảng 19h30 cùng ngày", "Từ nhà Nguyễn Phúc A cách 50m", hoặc đơn giản là "dao". Các mô hình trích xuất sự kiện hiện tại gặp khó khăn trong việc nhận diện và xử lý các đối số đồng tham chiếu này, và thay vì nhận dạng đúng đối số liên quan đến sự kiện, chúng lại tiếp tục trích xuất các đối số từ phần tiền sự kiện. Đây là một vấn đề quan trọng mà chúng tôi nhận diện và cho thấy là một thách thức lớn trong việc trích xuất sự kiện cấp độ văn bản, nơi các đối số có thể bị thay đổi cách diễn đạt mà không làm mất đi ngữ nghĩa ban đầu, dẫn đến lỗi nhận diện đối số.

Các lỗi còn lại chủ yếu liên quan đến việc mô hình không thể nhận dạng được các đối số cần thiết trong văn bản, hoặc xác định sai loại đối số liên quan đến sự kiện. Ví dụ, trong một số trường hợp, mô hình có thể nhận diện đúng sự kiện nhưng lại không nhận diện đầy đủ các đối số hoặc trích xuất sai loại đối số như thời gian, địa điểm, hoặc người tham gia sự kiện. Một số trường hợp khác, mô hình có thể trích xuất các phần không liên quan đến sự kiện, ví dụ như những phần thông tin không cần thiết hoặc tình huống không có tác động trực tiếp đến sự kiện chính. Những lỗi này chủ yếu do thiếu sót trong việc mô hình hóa ngữ nghĩa hoặc thiếu khả năng phân biệt ngữ cảnh giữa các đối số có liên quan và không liên quan.

Tổng quan lại, các lỗi được xác định trong quá trình thực nghiệm cho thấy nhiều thách thức trong việc xử lý văn bản pháp lý tiếng Việt, đặc biệt là trong việc nhận diện đối số đồng tham chiếu và xác định vùng văn bản chính xác. Những vấn đề này cần được giải quyết để cải thiện hiệu quả của các mô hình trích xuất sự kiện, đặc biệt là trong các tình huống văn bản dài và phức tạp, nơi thông tin sự kiện có thể bị phân tán và thay đổi trong cách diễn đạt qua các đoạn khác nhau.Các lỗi còn lại chủ yếu đến từ việc không nhận dạng được đối số, xác định sai loại đối số, loại sự kiện hoặc trích xuất nội dung không liên quan.

CHƯƠNG 7. KẾT LUẬN

7.1 Kết luận

VLEX là tập dữ liệu có ý nghĩa đối với hướng nghiên cứu trích xuất sự kiện trên tiếng Việt, trong đó tập dữ liệu được xây dựng với mục tiêu trở thành một thang đo thực nghiệm cho các mô hình trên miền ngôn ngữ tiếng Việt. Cụ thể, VLEX là tập dữ liệu thứ ba dành cho trích xuất sự kiện tiếng Việt, đồng thời là tập đầu tiên tập trung vào lĩnh vực pháp lý và cũng là tập đầu tiên triển khai trích xuất sự kiện ở cấp độ văn bản trên tiếng Việt, qua đó mở rộng đáng kể phạm vi đánh giá từ các thiết lập dựa trên câu sang thiết lập cấp độ văn bản với ngữ cảnh dài và thông tin phân tán. Bên cạnh đóng góp về dữ liệu, chúng tôi cũng trình bày một quy trình xây dựng tập dữ liệu mang tính toàn diện và có khả năng tái lập, mô tả rõ các bước từ thu thập và chuẩn hóa bản án, lựa chọn phạm vi và kiểm soát chất lượng nguồn, cho đến tổ chức gán nhãn trên công cụ chuyên dụng, thiết kế cơ chế đánh giá độ đồng thuận trong quá trình gán nhãn, nhằm bảo đảm dữ liệu đạt độ tin cậy cao cho nghiên cứu và ứng dụng. Cuối cùng, VLEX được khai thác theo thiết lập đa sự kiện ở cấp độ văn bản, trong đó một tài liệu có thể chứa nhiều sự kiện có liên hệ và bổ trợ lẫn nhau, tạo ra các tình huống phức tạp hơn so với giả định một sự kiện duy nhất mỗi văn bản; đặc trưng này đặt ra thách thức thực tiễn cho các mô hình khi phải đồng thời nhận diện nhiều sự kiện, tách biệt đúng từng sự kiện và liên kết đối số chính xác theo từng cấu trúc, từ đó giúp VLEX trở thành một bài kiểm tra giàu tính thử thách cho năng lực trích xuất đa sự kiện của các phương pháp hiện có và các hướng tiếp cận mới trong tương lai.

7.2 Hướng phát triển

Mặc dù VLEX đã đạt được các mục tiêu trọng tâm về quy mô, mức độ chi tiết của lược đồ và chất lượng gán nhãn, tập dữ liệu vẫn tồn tại một số giới hạn cần được nhìn nhận một cách thận trọng. Trước hết, phương pháp gán nhãn hoàn toàn thủ công, dù giúp bảo đảm độ chính xác và tính nhất quán khi xử lý văn bản pháp lý giàu hàm ý, vẫn đòi hỏi chi phí lớn về thời gian và nguồn lực, đặc biệt khi số lượng văn bản tăng và lược đồ sự kiện mở rộng theo hướng nhiều loại sự kiện và nhiều vai trò đối

số. Trong khi đó, sự phát triển nhanh của các mô hình ngôn ngữ lớn trong các nhiệm vụ hiểu và sinh ngôn ngữ mở ra khả năng hỗ trợ hiệu quả cho quá trình chú giải, nhất là ở các bước tốn công như đề xuất ứng viên từ kích hoạt, gợi ý đối số và kiểm tra tính đầy đủ của bản ghi sự kiện. Do vậy, hướng phát triển tiếp theo của chúng tôi tập trung vào việc cải tiến quy trình gán nhãn theo hướng bán tự động, trong đó mô hình ngôn ngữ lớn được tích hợp như một thành phần hỗ trợ ra quyết định nhằm giảm tải cho người gán nhãn nhưng vẫn duy trì cơ chế kiểm soát chất lượng dựa trên chuyên gia, ví dụ sử dụng mô hình để tạo đề xuất ban đầu, sau đó người gán nhãn thực hiện xác nhận, hiệu chỉnh và chuẩn hóa theo hướng dẫn.

Song song với cải tiến quy trình, chúng tôi xem đa sự kiện ở cấp độ văn bản là một hướng nghiên cứu giàu tiềm năng và có tính thách thức cao, bởi trong kịch bản thực tế của các văn bản pháp lý, nhiều sự kiện thường đồng thời xuất hiện, liên kết theo quan hệ nguyên nhân - hệ quả hoặc theo trình tự tố tụng, và các thành phần tham gia có thể được nhắc lại, thay vai hoặc chia sẻ giữa các sự kiện, khiến việc tách biệt ranh giới sự kiện và liên kết đối số trở nên khó khăn hơn đáng kể. Vì vậy, trong tương lai, chúng tôi dự kiến mở rộng phạm vi dữ liệu vượt ra ngoài miền Hình sự, hướng tới các lĩnh vực như Dân sự, Hôn nhân và gia đình, cũng như các nhóm văn bản pháp lý liên quan khác, nhằm tiếp cận nhiều kịch bản đa sự kiện hơn và tăng độ đa dạng về cấu trúc diễn ngôn. Việc mở rộng này không chỉ làm phong phú độ phủ miền và nâng cao tính đại diện của thang đo, mà còn tạo điều kiện hình thành một thang đánh giá thử thách hơn cho các mô hình trích xuất sự kiện tiếng Việt, đặc biệt đối với năng lực suy luận xuyên câu, hợp nhất thông tin rải rác và xử lý đồng thời nhiều sự kiện trong cùng một văn bản.

TÀI LIỆU THAM KHẢO

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In J. Burstein, C. Doran, & T. Solorio (Eds.), *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)* (pp. 4171–4186). Minneapolis, Minnesota: Association for Computational Linguistics. https://doi.org/10.18653/v1/N19-1423

Ebner, S., Xia, P., Culkin, R., Rawlins, K., & Van Durme, B. (2020). RAMS: Multi-Sentence Argument Linking. In D. Jurafsky, J. Chai, N. Schluter, & J. Tetreault (Eds.), *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (pp. 8057–8077). Online: Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.acl-main.718

Feng, Y., Li, C., & Ng, V. (2022). Legal Judgment Prediction via Event Extraction with Constraints. In S. Muresan, P. Nakov, & A. Villavicencio (Eds.), *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 648–664). Dublin, Ireland: Association for Computational Linguistics. https://doi.org/10.18653/v1/2022.acl-long.48

Guan, S., Cheng, X., Bai, L., Zhang, F., Li, Z., Zeng, Y., … Guo, J. (2022). What is Event Knowledge Graph: A Survey (Knowledge graph). *IEEE Transactions on Knowledge and Data Engineering*, 1–20. https://doi.org/10.1109/TKDE.2022.3180362

Guideline: ACE Event Descriptions (v5. (n.d.). Retrieved from https://www.ldc.upenn.edu/sites/www.ldc.upenn.edu/files/english-events-guidelines-v5.4.3.pdf

Han, C., Zhang, J., Li, X., Xu, G., Peng, W., & Zeng, Z. (2022a). DuEE-Fin: A Large-Scale Dataset for Document-Level Event Extraction. In W. Lu, S. Huang, Y. Hong, & X. Zhou (Eds.), *Natural Language Processing and Chinese Computing*

(pp. 172–183). Cham: Springer International Publishing. https://doi.org/10.1007/978-3-031-17120-8_14

Han, C., Zhang, J., Li, X., Xu, G., Peng, W., & Zeng, Z. (2022b). DuEE-Fin: A Large-Scale Dataset for Document-Level Event Extraction. In W. Lu, S. Huang, Y. Hong, & X. Zhou (Eds.), *Natural Language Processing and Chinese Computing* (pp. 172–183). Cham: Springer International Publishing. https://doi.org/10.1007/978-3-031-17120-8_14

Hoang, T., Nguyen, L., & Dinh, D. (2024). VHE: A New Dataset for Event Extraction from Vietnamese Historical Texts. In N. Oco, S. N. Dita, A. M. Borlongan, & J.-B. Kim (Eds.), *Proceedings of the 38th Pacific Asia Conference on Language, Information and Computation* (pp. 619–634). Tokyo, Japan: Tokyo University of Foreign Studies. Retrieved from https://aclanthology.org/2024.paclic-1.59/

Huang, Y., & Jia, W. (2021). Exploring Sentence Community for Document-Level Event Extraction. In M.-F. Moens, X. Huang, L. Specia, & S. W. Yih (Eds.), *Findings of the Association for Computational Linguistics: EMNLP 2021* (pp. 340–351). Punta Cana, Dominican Republic: Association for Computational Linguistics. https://doi.org/10.18653/v1/2021.findings-emnlp.32

Ji, H., & Grishman, R. (2011). Knowledge Base Population: Successful Approaches and Challenges. In D. Lin, Y. Matsumoto, & R. Mihalcea (Eds.), *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies* (pp. 1148–1158). Portland, Oregon, USA: Association for Computational Linguistics. Retrieved from https://aclanthology.org/P11-1115/

Joshi, A., Sharma, A., Tanikella, S. K., & Modi, A. (2023). U-CREAT: Unsupervised Case Retrieval using Events extrAcTion. In A. Rogers, J. Boyd-Graber, & N. Okazaki (Eds.), *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 13899–13915). Toronto, Canada: Association for Computational Linguistics. https://doi.org/10.18653/v1/2023.acl-long.777

Klie, J.-C., Bugert, M., Boullosa, B., Eckart de Castilho, R., & Gurevych, I. (2018). The INCEpTION Platform: Machine-Assisted and Knowledge-Oriented Interactive Annotation. In D. Zhao (Ed.), *Proceedings of the 27th International Conference on Computational Linguistics: System Demonstrations* (pp. 5–9). Santa Fe, New Mexico: Association for Computational Linguistics. Retrieved from https://aclanthology.org/C18-2002/

Li, C., Sheng, Y., Ge, J., & Luo, B. (2019). Apply event extraction techniques to the judicial field. *Adjunct Proceedings of the 2019 ACM International Joint Conference on Pervasive and Ubiquitous Computing and Proceedings of the 2019 ACM International Symposium on Wearable Computers*, 492–497. London United Kingdom: ACM. https://doi.org/10.1145/3341162.3345608

Li, S., Ji, H., & Han, J. (2021). Document-Level Event Argument Extraction by Conditional Generation. In K. Toutanova, A. Rumshisky, L. Zettlemoyer, D. Hakkani-Tur, I. Beltagy, S. Bethard, … Y. Zhou (Eds.), *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (pp. 894–908). Online: Association for Computational Linguistics. https://doi.org/10.18653/v1/2021.naacl-main.69

McHugh, M. L. (2012). Interrater reliability: The kappa statistic. *Biochemia Medica*, 276–282. https://doi.org/10.11613/BM.2012.031

Nguyen, T.-N., Tran, B. T., Luu, T.-N., Nguyen, T. H., & Nguyen, K.-H. (2024). BKEE: Pioneering Event Extraction in the Vietnamese Language. In N. Calzolari, M.-Y. Kan, V. Hoste, A. Lenci, S. Sakti, & N. Xue (Eds.), *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)* (pp. 2421–2427). Torino, Italia: ELRA and ICCL. Retrieved from https://aclanthology.org/2024.lrec-main.217/

Premasiri, D., Ranasinghe, T., Mitkov, R., El-Haj, M., & Frommholz, I. (2025). Survey: Survey on legal information extraction: Current status and open challenges. *Knowledge and Information Systems*, *67*(12), 11287–11358. https://doi.org/10.1007/s10115-025-02600-5

Tong, M., Xu, B., Wang, S., Han, M., Cao, Y., Zhu, J., … Li, J. (2022). DocEE: A Large-Scale and Fine-grained Benchmark for Document-level Event Extraction. *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 3970–3982. Seattle, United States: Association for Computational Linguistics. https://doi.org/10.18653/v1/2022.naacl-main.291

Wei, K., Shi, X., Tong, J., Reddy, S. R., Natarajan, A., Jain, R., … Huang, R. (2025). LegalCore: A Dataset for Event Coreference Resolution in Legal Documents. In W. Che, J. Nabende, E. Shutova, & M. T. Pilehvar (Eds.), *Findings of the Association for Computational Linguistics: ACL 2025* (pp. 25044–25059). Vienna, Austria: Association for Computational Linguistics. https://doi.org/10.18653/v1/2025.findings-acl.1284

Xian, G., Du, S., Tang, X., Shi, Y., Jia, B., Tang, B., … Li, L. (2024). DLEE: A dataset for Chinese document-level legal event extraction. *Neural Computing and Applications*, *36*(25), 15581–15597. https://doi.org/10.1007/s00521-024-09907-4

Xiang, W., & Wang, B. (2019). Survey: A Survey of Event Extraction From Text. *IEEE Access*, *7*, 173111–173137. https://doi.org/10.1109/ACCESS.2019.2956831

Xu, R., Liu, T., Li, L., & Chang, B. (2021). GIT: Document-level Event Extraction via Heterogeneous Graph-based Interaction Model with a Tracker. In C. Zong, F. Xia, W. Li, & R. Navigli (Eds.), *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)* (pp. 3533–3546). Online: Association for Computational Linguistics. https://doi.org/10.18653/v1/2021.acl-long.274

Yang, H., Chen, Y., Liu, K., Xiao, Y., & Zhao, J. (2018). DCFEE: A Document-level Chinese Financial Event Extraction System based on Automatically Labeled Training Data. In F. Liu & T. Solorio (Eds.), *Proceedings of ACL 2018,*

System Demonstrations (pp. 50–55). Melbourne, Australia: Association for Computational Linguistics. https://doi.org/10.18653/v1/P18-4009

Yao, F., Xiao, C., Wang, X., Liu, Z., Hou, L., Tu, C., … Sun, M. (2022). LEVEN: A Large-Scale Chinese Legal Event Detection Dataset. In S. Muresan, P. Nakov, & A. Villavicencio (Eds.), *Findings of the Association for Computational Linguistics: ACL 2022* (pp. 183–201). Dublin, Ireland: Association for Computational Linguistics. https://doi.org/10.18653/v1/2022.findings-acl.17

Zheng, S., Cao, W., Xu, W., & Bian, J. (2019). Doc2EDAG: An End-to-End Document-level Framework for Chinese Financial Event Extraction. In K. Inui, J. Jiang, V. Ng, & X. Wan (Eds.), *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)* (pp. 337–346). Hong Kong, China: Association for Computational Linguistics. https://doi.org/10.18653/v1/D19-1032

Zhu, T., Qu, X., Chen, W., Wang, Z., Huai, B., Yuan, N., & Zhang, M. (2022). PTPCG: Efficient Document-level Event Extraction via Pseudo-Trigger-aware Pruned Complete Graph. *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence*, 4552–4558. Vienna, Austria: International Joint Conferences on Artificial Intelligence Organization. https://doi.org/10.24963/ijcai.2022/632